

Detección de fraude eléctrico con aprendizaje automático: una comparativa aplicada entre modelado tabular y series temporales



Universitat
Oberta
de Catalunya

Carlos Castaño Santos

Ciencia de Datos Aplicada
Minería de datos

Nombre Tutor/a de TF

Carlos Gaitán Poyatos

**Profesor/a responsable
de la asignatura**

Susana Acedo Nadal

4 de junio de 2026



Esta obra está sujeta a una licencia de Reconocimiento-NoComercial-CompartirIgual [3.0 España de Creative Commons](https://creativecommons.org/licenses/by-nc-sa/3.0/)

FICHA DEL TRABAJO FINAL

Título del trabajo:	Detección de fraude eléctrico con aprendizaje automático: una comparativa aplicada entre modelado tabular y series temporales
Nombre del autor:	Carlos Castaño Santos
Nombre del director/a:	Carlos Gaitán Poyatos
Nombre del PRA:	Susana Acedo Nadal
Fecha de entrega (mm/aaaa):	06/2026
Titulación o programa:	Ciencia de Datos Aplicada
Área del Trabajo Final:	Minería de datos
Idioma del trabajo:	Castellano
Palabras clave	Detección de fraude eléctrico, Series temporales, Aprendizaje automático
Resumen del Trabajo	
Este trabajo presenta un estudio comparativo entre dos enfoques metodológicos para la detección de fraude eléctrico sobre el <i>dataset</i> público SGCC: el modelado tabular basado en ingeniería de características y el aprendizaje profundo sobre series temporales de consumo. El enfoque tabular combina extracción automática de características y variables diseñadas a partir del análisis exploratorio, generando conjuntos de entre 160 y 247 variables. Tras la selección mediante <i>BorutaSHAP</i>, se reduce a aproximadamente 50 variables sin pérdida de rendimiento. Se evalúan tres modelos basados en <i>tree ensembles</i> y dos estrategias de ensamblado que los combinan. <i>XGBoost</i> logra el mejor resultado con un <i>ROC-AUC</i> de 0.865 y un <i>MCC</i> de 0.464. El enfoque profundo implementa <i>MSCNN-AT</i>, una arquitectura que procesa las series temporales mediante ramas convolucionales paralelas con <i>kernels</i> de distintas escalas temporales, seguidas de un mecanismo de agregación que combina <i>pooling</i> mixto y atención. El modelo obtiene un <i>ROC-AUC</i> de 0.907 y un <i>MCC</i> de 0.595, situándose entre los mejores resultados del estado del arte. Más allá del rendimiento predictivo, el trabajo adopta una perspectiva operativa orientada a la utilidad real de los modelos, considerando la representatividad de la muestra, el tipo de error, la explicabilidad y el coste computacional.	

Índice

1. Introducción	5
1.1. Contexto y justificación del trabajo	5
1.2. Estado del arte (SOTA) y otras soluciones	6
1.3. Aportación	8
1.4. Objetivos del trabajo	9
1.5. Impacto en sostenibilidad, ético-social y de diversidad	9
1.6. Enfoque y método seguido	10
1.7. Planificación del trabajo	11
1.8. Breve resumen de productos obtenidos	13
1.9. Breve descripción de los otros capítulos de la memoria	13
1.10. Declaración sobre el uso de inteligencia artificial generativa	13
2. Materiales y métodos	14
2.1 Fuente de datos	14
2.2. Análisis exploratorio de datos (EDA)	14
2.3. Preprocesamiento compartido	22
2.4. Marco general de evaluación	23
2.5. Enfoque tabular	25
2.6. Enfoque profundo sobre series temporales	34
3. Resultados	38
3.1. Consideraciones metodológicas sobre la evaluación	38
3.2. Resultados del enfoque tabular	38
3.3. Resultados del enfoque profundo temporal y comparativa	39
3.4. Comparativa con el estado del arte	41
3.5. Explicabilidad de los modelos	42
3.6. Productos obtenidos y viabilidad	46
4. Conclusiones y trabajos futuros	47
4.1. Conclusiones principales del trabajo	47
4.2. Limitaciones del modelo	48
4.3. Objetivos, seguimiento de la metodología y riesgos	49
4.4. Impacto ético, social y de sostenibilidad	49
4.5. Trabajos futuros	50
5. Glosario	51
6. Bibliografía	53
7. Anexos	56

Lista de figuras

Figura 1. Planificación, diagrama de Gantt.	12
Figura 2. Consumo agregado por clase y tiempo.	15
Figura 3. Distribución de nulos y ceros.	16
Figura 4. Distribución de nulos y ceros por clase.	16
Figura 5. Distribución de rachas de ceros por cliente y clase.	17
Figura 6. Desconexiones y rachas de desconexiones.	17
Figura 7. Clientes con consumo diario superior a 10,000.	19
Figura 8. Descomposición <i>STL</i> agregado por mediana y clase, periodo = 365.	19
Figura 9. Descomposición <i>STL</i> agregado por mediana y clase, periodo = 30.	20
Figura 10. Descomposición <i>STL</i> agregado por mediana y clase, periodo = 7.	20
Figura 11. <i>ACF</i> media por clase.	21
Figura 12. Extracción de características.	26
Figura 13. Diagrama <i>Boruta</i> .	29
Figura 14. <i>BorutaSHAP</i> en <i>LightGBM</i> , prueba de rendimiento en validación.	30
Figura 15. Ejemplo ilustrativo: métodos <i>oversampling</i> .	31
Figura 16. Ejemplo ilustrativo: métodos <i>hybrid resampling</i> y <i>NearMiss-v3</i> .	32
Figura 17. Evaluación de estrategias <i>resampling</i> .	33
Figura 18. Arquitectura <i>MSCNN-AT</i> .	37
Figura 19. Curva Precisión-Recall, misma semilla única y partición.	40
Figura 20. Comparativa <i>SOTA</i> : <i>ROC-AUC</i> .	41
Figura 21. Importancias nativas de <i>XGBoost</i> .	42
Figura 22. Importancia <i>SHAP Bar</i> (izquierda) y <i>SHAP Beeswarm</i> (derecha).	43
Figura 23. Gráficos <i>SHAP Waterfall</i> : verdadero positivo (izquierda) y falso positivo (derecha).	43
Figura 24. Atención promedio mensual en clientes fraudulentos.	44
Figura 25. Explicabilidad local por atención temporal.	45
Figura 26. Sensibilidad por oclusión, ventanas de 30 y 7 días.	46
Figura 27. Tiempo de entreno e inferencia en distintos entornos.	47
Figura 28. Distribución temporal de valores nulos.	48

Lista de tablas

Tabla 1. <i>SOTA</i> , detección de fraude eléctrico.	6
Tabla 2. Trabajos relevantes con <i>data leakage</i> .	8
Tabla 3. Hitos y tareas.	11
Tabla 4. Impacto muestral en caso de filtrar clientes por rachas nulas.	18
Tabla 5. Proporción de fraude con <i>outliers</i> : $IQR \cdot \text{Factor}$.	18
Tabla 6. Preprocesamiento compartido.	23
Tabla 7. Métricas de error.	24
Tabla 8. Métricas de separabilidad.	25
Tabla 9. Imputación de nulos para <i>TSFEL</i> .	27
Tabla 10. Elección del dataset final.	28
Tabla 11. Comparativa de rendimiento tras la optimización de hiperparámetros.	34
Tabla 12. <i>MSCNN-AT</i> , hiperparámetros de entrenamiento.	38
Tabla 13. Enfoque tabular: métricas de error.	39
Tabla 14. Métricas de error <i>MSCNN-AT</i> .	40

1. Introducción

Este capítulo presenta el marco general del trabajo y delimita el problema de detección de fraude eléctrico desde una perspectiva técnica, operativa y metodológica. Para ello, se contextualiza la relevancia del fraude en redes eléctricas, se revisan las principales aproximaciones existentes, se concreta la aportación del proyecto y se establecen los objetivos, el enfoque seguido y la organización de la memoria.

1.1. Contexto y justificación del trabajo

El consumo mundial de electricidad se ha incrementado de forma sostenida durante las últimas décadas, llegando prácticamente a triplicarse desde 1990, según datos de la Agencia Internacional de la Energía (IEA, 2023) ^[1]. Este crecimiento ha intensificado la necesidad de mejorar la eficiencia de los sistemas de generación, transmisión y distribución eléctrica, especialmente en un contexto marcado por la electrificación progresiva de la economía y la transición energética.

Dentro de este escenario, las pérdidas energéticas continúan representando uno de los principales desafíos operativos para las compañías distribuidoras. El Banco Mundial (2023) ^[2] estima que aproximadamente un 6% de la energía producida a nivel global no llega a facturarse, aunque existen diferencias regionales muy significativas entre países. Por ejemplo, mientras España registra pérdidas cercanas al 9%, otros países como Argentina alcanzan el 24% e Iraq supera el 60%. Estas pérdidas suelen clasificarse en dos grandes grupos: pérdidas técnicas, derivadas de limitaciones físicas de la infraestructura eléctrica; y pérdidas no técnicas (PNT), asociadas principalmente a errores administrativos, fallos de medición y fraude eléctrico.

Entre las PNT, el fraude eléctrico constituye uno de los problemas más relevantes por su impacto económico, operativo y social. La Comisión Nacional de los Mercados y la Competencia (CNMC, 2015) ^[3] define este fenómeno como la manipulación de los equipos de medida o la alteración directa de la red eléctrica con el objetivo de evitar el pago del consumo real.

Al margen del perjuicio económico para las distribuidoras, el fraude eléctrico puede repercutir en las facturas de los consumidores legítimos por el encarecimiento del sistema. En esta línea, la IEA (2023) ^[4] señala un repunte reciente del fraude y de las conexiones ilegales en distintos países, especialmente en contextos de presión económica y de aumento del coste energético, lo que refuerza la necesidad de mecanismos de detección más robustos.

Tradicionalmente, la detección de fraudes se ha apoyado en reglas de negocio, inspecciones aleatorias y revisiones manuales de consumo. Sin embargo, la digitalización de las infraestructuras eléctricas y la disponibilidad masiva de datos procedentes de contadores inteligentes han favorecido el desarrollo de enfoques basados en aprendizaje automático. En este contexto, el Banco Interamericano de Desarrollo (2024) ^[5] destaca el potencial de la inteligencia artificial para identificar patrones de consumo anómalos y optimizar la selección de inspecciones.

La utilidad práctica de estas técnicas ya se ha observado en entornos reales. La distribuidora Edenor, por ejemplo, reportó mejoras sustanciales tras incorporar modelos predictivos, elevando su tasa de acierto del 42.4% en 2017 al 54% en 2020 y multiplicando casi por siete la energía recuperada ^[5]. Este tipo de resultados evidencia el interés operativo y económico de desarrollar sistemas automatizados capaces de priorizar clientes potencialmente fraudulentos.

En este escenario, el presente TFG (Trabajo Final de Grado) se enmarca en el desarrollo de técnicas de aprendizaje automático aplicadas a la detección de fraude eléctrico sobre datos abiertos de consumo energético, poniendo especial énfasis en su aplicabilidad.

1.2. Estado del arte (SOTA) y otras soluciones

La creciente disponibilidad de datos eléctricos y el avance de las técnicas de inteligencia artificial han impulsado un notable aumento de publicaciones académicas centradas en la detección de fraude eléctrico. La literatura reciente recoge propuestas muy diversas, desde modelos clásicos de aprendizaje automático hasta arquitecturas profundas específicamente diseñadas para las series temporales.

La *Tabla 1* resume algunos de los trabajos más representativos identificados durante la revisión bibliográfica.

Referencia	Dataset	Metodología principal	Métricas
Arif et al. (2022) ^[6]	SGCC/ PREC ON	Integración del consumo eléctrico y variables auxiliares del hogar. Una Red Convolutiva Temporal (TCN) modela la serie de consumo y el Perceptrón Multicapa (EMLP) trata los datos no secuenciales. Se aplica un método propio (TBSSVM) para balancear clases y un ensamblado por promedio de varios TCN-EMLP.	ROC-AUC: 0.80 - 0.84 (tras TBSSVM)
Gunturi y Sarkar (2021) ^[7]	CER Dublín	Clasificación binaria sobre 48 lecturas diarias. Se mide el rendimiento al escalar de 1 a 100 usuarios con 6 categorías de robo eléctrico aumentadas por SMOTE. Pese a un buen rendimiento de XGBoost y LightGBM, Random Forest y Extra Trees los superan al escalar.	ROC-AUC: 0.90
Farid et al. (2023) ^[8]	SGCC	Se utiliza como <i>input</i> las series temporales y una máscara binaria de nulos. Combinando una <i>Spatial Transformer Network</i> (STN) para rotar y escalar las entradas antes de alimentar una CNN. Sobremuestreo con SMOTE.	ROC-AUC: 0.92; F1: 0.87
Zheng et al. (2018) ^[9]	SGCC	Arquitectura CNN con dos componentes paralelos: <i>wide</i> (1D, serie diaria) y <i>deep</i> (2D, agregado semanal). Diseñado para generalizar y extraer características complejas sobre los perfiles de fraude.	ROC-AUC: 0.80
Bohani et al. (2021) ^[10]	SGCC	Marco comparativo entre algoritmos tradicionales y redes neuronales artificiales. No se usan técnicas de balance de clases. Tan solo se imputan nulos y se escalan datos; exponiendo el rendimiento base sobre los datos desbalanceados.	ROC-AUC: 0.77
Mohammad et al. (2023) ^[11]	ETD2022	Sistema de predicción multiclase basado en la integración de clasificadores heterogéneos (KNN, Random Forest, XGBoost y MLP). Supera a una red neuronal. Se emplea voto por mayoría.	Exactitud: 0.88 - 0.94; Detección: 0.88-0.95

Tabla 1. SOTA, detección de fraude eléctrico.

En términos generales, la literatura reciente muestra una tendencia hacia arquitecturas cada vez más complejas e híbridas. Diversos trabajos emplean redes neuronales convolucionales, modelos basados en árboles y estrategias de ensamblado, con el objetivo de capturar patrones temporales y no lineales difíciles de representar mediante enfoques tradicionales. Para ello, es habitual recurrir también a técnicas de balanceo de clases que compensen la asimetría en los datos.

De forma complementaria, también se han identificado otros trabajos especialmente relevantes, pero que presentan limitaciones experimentales dada la potencial presencia de *data leakage* en distintos puntos del *pipeline*.

La *Tabla 2* recoge estos trabajos por un doble motivo. En primer lugar, porque muchas propuestas metodológicas y conclusiones resultan útiles como inspiración para el desarrollo de este TFG. En segundo lugar, porque permiten contextualizar adecuadamente los resultados obtenidos en la literatura y diferenciar entre métricas derivadas de configuraciones metodológicamente robustas y otras potencialmente afectadas por problemas de validación.

Referencia	Metodología/Conclusiones	Evidencia <i>data leakage</i>
Hussain et al. (2021) ^[12]	Extracción de variables tabulares mediante la librería <i>TSFEL</i> . Selección de características con el Algoritmo de Optimización de Ballenas (WOA). <i>NGBoost</i> como modelo predictivo final.	<i>"The minority class samples [...] were merged with the original dataset [...]"</i>
Elshennawy et al. (2025) ^[13]	Extracción de características en paralelo mediante tres ramas (CNN, LSTM y CNN-LSTM). Las representaciones se concatenan y pasan a un clasificador final.	<i>"Initially, [...] class imbalance [...] is addressed using LoRAS. Subsequently, the dataset is split"</i>
Kawoosa et al. (2023) ^[14]	Fusión de datos eléctricos con información auxiliar (clima, geografía). Se crean variables objetivo en función del tipo de fraude. Creación de variables tabulares, redimensionadas con PCA. Clasificación con <i>XGBoost</i> .	<i>"randomly selected 50%[...] 9998 samples to generate malicious samples. 70% of the samples [...] as the training set, while the remaining 30% comprised the test"</i>
Bai et al. (2024) ^[15]	Segmentación de datos combinado con <i>Catch22</i> (librería) para extracción tabular. Transformación de características a secuencias de <i>tokens</i> . Clasificación mediante un <i>Transformer</i> con atención multicabeza.	<i>"18,000 samples [...] normal samples were mixed [...] which was then divided into training, validation, and testing sets"</i>
Pamir et al. (2023) ^[16]	Modelo híbrido profundo optimizado con técnicas metaheurísticas (SSA-GCAE-CSLSTM) para la extracción de características. <i>XGBoost</i> logra resultados similares pero es 330 veces más eficiente.	<i>"preprocessing [...] where MM scaler, TSR, and LI are employed. The entire data set is split [...] at a later stage."</i>
Iqbal et al. (2025) ^[17]	Se evalúan cuatro estrategias de <i>Transfer Learning</i> (congelación de capas, <i>fine-tuning</i>) utilizando pesos de arquitecturas preentrenadas (<i>BiGRU-BiLSTM</i> y <i>LSTM CNN</i>).	<i>"15762 [...] samples were generated [...] This augmented data was then used for training and testing". "The normalized data are split into training and testing"</i>

Kabir et al. (2025) ^[18]	Ensamble optimizado con un algoritmo de luciérnaga (FA). <i>SMOTE</i> y <i>ENN</i> para evitar solapamiento en la frontera de decisión. Añade explicabilidad (<i>SHAP</i>) sobre las fechas.	Submuestreo arbitrario de 321 usuarios. Evaluación realizada sobre datos sintéticos. Ver Figura 13.
-------------------------------------	--	---

Tabla 2. Trabajos relevantes con *data leakage*.

Más allá del problema del *data leakage*, estas propuestas incluyen distintas estrategias de generación de muestras sintéticas para resolver el problema del desbalance propio del fraude; modelos basados en árboles que favorecen la transparencia del predictor final manteniendo, a la vez, una mayor eficiencia computacional; el uso de librerías especializadas para la extracción masiva de características; así como modelos híbridos y profundos.

En conjunto, la literatura revisada evidencia que la detección de fraude eléctrico continúa siendo un problema abierto y complejo, donde los avances en rendimiento predictivo suelen ir acompañados de un aumento considerable de la complejidad arquitectónica y computacional. También son frecuentes otras limitaciones como el uso de muestras excesivamente filtradas, el empleo de métricas insuficientes para escenarios desbalanceados o la ausencia de mecanismos claros de interpretabilidad.

1.3. Aportación

A pesar del volumen de publicaciones académicas sobre la detección de fraude eléctrico, la revisión bibliográfica ha permitido identificar limitaciones recurrentes que este TFG pretende abordar.

La primera de ellas está relacionada con la reproducibilidad y la transparencia. Ninguno de los trabajos analizados publica repositorios de código, lo que dificulta la validación independiente de resultados, la reutilización de las propuestas y su uso. Asimismo, muchas publicaciones centran la evaluación casi exclusivamente en métricas globales de separabilidad, como en *ROC-AUC* ^[6, 9] o en medidas agregadas que no distinguen el comportamiento de cada clase ^[10, 12, 16, 17]. Este tipo de evaluación puede enmascarar el impacto real de los falsos positivos y falsos negativos sobre consumidores y distribuidoras.

Otra limitación identificada es la representatividad de los datos utilizados. Algunos trabajos aplican filtrados intensivos o submuestreos que excluyen una parte considerable de los clientes con registros incompletos o comportamientos irregulares ^[6, 12], simplificando la complejidad real de la base de datos para adaptar el problema a determinadas metodologías. Del mismo modo, varias propuestas construyen sus evaluaciones sobre muestras sintéticas o escenarios excesivamente controlados ^[14, 15, 17, 18], alejándose parcialmente de las condiciones reales en las que estos sistemas deberían aplicarse.

Por último, la interpretabilidad continúa siendo uno de los principales retos del área. En un contexto real, un sistema de detección de fraude debe permitir justificar las alertas generadas y facilitar su análisis por parte de operarios e inspectores. La capacidad explicativa del modelo no solo resulta relevante desde una perspectiva técnica y operativa, sino también desde el punto de vista ético y regulatorio.

En este contexto, el presente trabajo propone una aproximación centrada en cuatro ejes principales:

- El desarrollo de un *pipeline* reproducible y transparente.
- La comparación entre enfoques tabulares y arquitecturas profundas temporales en función de intereses operativos.
- La evaluación mediante métricas adaptadas a escenarios desbalanceados y a tipos de error.
- La interpretabilidad y viabilidad práctica de las soluciones obtenidas.

De este modo, el objetivo no es únicamente maximizar el rendimiento predictivo, sino estudiar hasta qué punto distintas estrategias de modelado resultan realmente útiles, explicables y aplicables en escenarios cercanos a un entorno operativo real.

1.4. Objetivos del trabajo

El desarrollo se estructura a partir de una serie de objetivos generales y específicos orientados tanto al diseño experimental como a la evaluación práctica de las soluciones propuestas.

(i) Objetivos generales

- **OG1.** Desarrollar una solución metodológicamente robusta y transparente —a través del código— para la detección de fraude eléctrico sobre un conjunto de datos abiertos.
- **OG2.** Comparar la estrategia tabular basada en algoritmos de *Machine Learning* con el uso directo de la señal de consumo mediante *DL* (*Deep Learning*); buscando determinar la mejor aproximación en función de las métricas obtenidas, las consecuencias prácticas de los distintos tipos de error, la escalabilidad del sistema y la explicabilidad del modelo.

(ii) Objetivos específicos

- **OE1.** Realizar un análisis exploratorio de datos suficiente para cuantificar la proporción exacta de clases, el volumen de registros inconsistentes (nulos, negativos, secuencias de ceros o errores de medición), identificar patrones estadísticos asociados al fraude y definir estrategias de preprocesamiento.
- **OE2.** Generar al menos 100 variables explicativas tabulares que sinteticen la información contenida en las series temporales, aplicando posteriormente un método de selección que reduzca el ruido y la redundancia.
- **OE3.** Evaluar mediante métricas de separabilidad el rendimiento de distintas técnicas de preprocesamiento —especialmente estrategias de *resampling*—, al menos tres algoritmos tabulares y un meta-modelo basado en *stacking*.
- **OE4.** Comprobar mediante métricas de error si la configuración final alcanza el rendimiento base reportado por Bohani et al. (2021) ^[10], así como la distancia respecto a modelos considerados *SOTA*.

1.5. Impacto en sostenibilidad, ético-social y de diversidad

El presente TFG se desarrolla en un contexto estrictamente académico, por lo que no contempla su despliegue en producción ni su comercialización. Sin embargo, su diseño parte de la responsabilidad de plantear un sistema que, en un escenario aplicado, se clasificaría como de «Alto Riesgo» bajo el Anexo III (apartado 2) de la

reciente *EU Artificial Intelligence Act*. Por ello, pese a no implementarse las obligaciones regulatorias asociadas, se consideran tres dimensiones clave:

(i) Sostenibilidad

Se espera generar un impacto positivo sobre la sostenibilidad medioambiental y la eficiencia de las infraestructuras, alineándose con el ODS 7 (Energía asequible y no contaminante), ODS 9 (Industria, innovación e infraestructura), ODS 12 (Producción y consumo responsables) y ODS 15 (Acción climática). Al mejorar la detección del fraude eléctrico, se reduce el desperdicio de recursos energéticos que deben ser generados. Además, al aumentar la tasa de acierto de las inspecciones, disminuyen los desplazamientos innecesarios, reduciendo la huella de carbono asociada a la logística.

(ii) Comportamiento ético y responsabilidad social

El fraude eléctrico genera un déficit económico que las compañías distribuidoras suelen derivar a las tarifas del resto de usuarios. Combatirlo contribuye a un sistema más justo y equitativo (ODS 16).

Desde un punto de vista normativo y ético, al tratarse de un entorno aislado sin impacto real sobre personas físicas, no se activan las obligaciones del RGPD (Arts. 12-22). También se han considerado los siguientes principios de investigación responsable relacionados con la *AI Act*:

- La identificación preliminar de riesgos (Art. 9.2) sobre las partes involucradas.
- La revisión de sesgos por evaluación e interpretabilidad (Art. 10), relacionado con la necesidad de la supervisión humana (Art. 14) para emitir la alerta y proteger al cliente honesto frente a decisiones automatizadas.
- La atención a la robustez y consistencia técnica de las métricas (Art. 15).

(iii) Diversidad y derechos humanos

En relación con el ODS 10 (Reducción de las desigualdades), el riesgo de sesgo se mitiga, en primer lugar, por la propia naturaleza del conjunto de datos. Este es anónimo, abierto y compuesto exclusivamente por registros temporales de consumo eléctrico, sin incluir variables demográficas, de género o socioeconómicas. Reduciendo significativamente los riesgos relacionados con la privacidad, la seguridad de los datos y la afectación discriminatoria (ODS 5) hacia cualquier colectivo.

1.6. Enfoque y método seguido

El planteamiento de este trabajo prioriza la extracción de características tabulares para su evaluación mediante algoritmos de *Machine Learning*, alineándose con diversas tendencias recientes de la literatura [10, 11, 12, 14, 15]. Esta estrategia constituye el eje principal de la planificación debido a que los modelos basados en *tree ensembles* continúan mostrando un rendimiento competitivo en problemas tabulares, ofreciendo además ventajas importantes en interpretabilidad y eficiencia computacional frente a arquitecturas profundas más complejas [16].

De forma complementaria, y condicionado al cumplimiento de los plazos del proyecto, el plan de trabajo contempla la experimentación con técnicas de *DL* aplicadas directamente sobre la señal temporal. Este tipo de enfoques ha mostrado resultados prometedores en distintos trabajos recientes [6, 8, 9], especialmente mediante arquitecturas convolucionales e híbridas.

No obstante, para que estas arquitecturas se consideren una alternativa preferente dentro del presente trabajo, deberán aportar mejoras suficientemente significativas respecto al enfoque tabular, justificando así su mayor coste computacional y su menor interpretabilidad.

En ambos casos, se opta por desarrollar un sistema predictivo desde cero, descartando la reutilización directa de herramientas preexistentes debido a la limitada transparencia observada durante la revisión bibliográfica. Asimismo, priorizar inicialmente el enfoque tabular constituye una estrategia coherente con los objetivos del proyecto, ya que incluso en el escenario de no completar la comparativa final con *DL*, seguirían garantizándose aspectos fundamentales como la transparencia del proyecto (OG1), la generación de variables explicativas (OE2), la evaluación experimental (OE3) y la comparación con la literatura existente (OE4).

1.7. Planificación del trabajo

El plan de trabajo se estructura de acuerdo con los plazos y entregas parciales establecidos por la UOC (PECs). La *Tabla 3* resume los principales hitos del proyecto y las tareas asociadas a cada uno de ellos.

Hito	Descripción	Tarea
1. Investigación y seguimiento	Entrega del primer informe de seguimiento (T3) y el código parcial (T1 y T2). Se reportará el grado de cumplimiento de los objetivos OE1 y OE2, justificando las variables obtenidas y desviaciones sobre el plan inicial.	T1. Análisis de datos y preprocesamiento tabular.
		T2. Primera extracción de características tabulares con la librería <i>TSFEL</i> .
2. Investigación y seguimiento	Entrega del informe de seguimiento (T6) y código (T4, T5, T5.5). Se evidenciará el cumplimiento de objetivos y avance.	T4. Añadir variables tabulares de dominio.
		T5. Iteración <i>ML</i> : modelos únicos, <i>stacking</i> , evaluación, etc.
		T5.5. Iteración <i>DL</i> y comparativa.
3. Memoria y presentación	Entrega de documentos finales.	T8. Redacción memoria.
		T9. Presentación y vídeo.
4. Defensa frente al tribunal	Sesión síncrona o asíncrona dedicada a responder preguntas, defender las decisiones de diseño y justificar los resultados.	T10. Preparación defensa.

Tabla 3. Hitos y tareas.

La distribución temporal de las tareas se representa en el siguiente diagrama de Gantt.




Figura 1. Planificación, diagrama de Gantt.

(i) Recursos

Además del acceso a material académico y software especializado, los recursos necesarios para realizar la experimentación del proyecto son los siguientes:

- Equipo local: sistema operativo Windows 10, procesador Intel Core i5-8600K, 16 GB de memoria RAM DDR4, almacenamiento SSD Kingston SUV500 de 120 GB y tarjeta gráfica NVIDIA GeForce GTX 1060 6B.
- Entorno en la nube: *Google Colab* con GPU NVIDIA Tesla T4 (15 GB VRAM), 12.7 GB RAM y CUDA 13.0.

(ii) Riesgos

Durante el desarrollo del proyecto, se identifican tres riesgos principales. El de mayor impacto ya se ha descrito en el apartado 1.6 y corresponde a la posible incapacidad de completar la iteración experimental de *DL*. Para los otros dos riesgos identificados, se plantean medidas de mitigación y planes de contingencia específicos.

- Recursos computacionales insuficientes para *DL* (probabilidad alta, impacto bajo).
 - Mitigación: se priorizará la optimización del código mediante técnicas como *early stopping* en el entorno gratuito de *Google Colab*.
 - Plan de contingencia: se contempla un presupuesto aproximado de 11.19 € para la adquisición de 100 unidades computacionales.
- Falta de reproducibilidad en los resultados (probabilidad media, impacto medio).
 - Causa: necesidad de múltiples procesos de *shuffle*, *bagging* de columnas y muestras, así como de distintas inicializaciones de modelos.
 - Mitigación: se usará una semilla global para todo el proyecto.

1.8. Breve resumen de productos obtenidos

Al finalizar el proyecto, y en cumplimiento con los hitos marcados, se entregarán los siguientes ítems:

- **Memoria:** presente documento que recogerá todo el ciclo de vida del proyecto.
- **Presentación virtual:** vídeo de duración inferior a 20 minutos sustentado por una presentación gráfica que ofrezca una perspectiva general del TFG y recoja los aspectos más relevantes.
- **Repositorio:** su principal valor será evidenciar un flujo de trabajo transparente y reproducible que incluirá datos, scripts, *Jupyter notebooks* y modelos finales.

1.9. Breve descripción de los otros capítulos de la memoria

El resto de capítulos de la memoria se organiza siguiendo el flujo experimental y analítico del proyecto:

El capítulo 2 presenta la fuente de datos y las metodologías empleadas durante el desarrollo del trabajo. Incluye el análisis exploratorio de datos, las estrategias de preprocesamiento, la extracción de características tabulares, los métodos de selección de variables, la optimización de hiperparámetros y el diseño de la arquitectura de *Deep Learning*.

El capítulo 3 recoge los resultados obtenidos durante la experimentación. En este, se comparan los distintos modelos evaluados mediante métricas de separabilidad y error, incorporando un análisis de interpretabilidad, eficiencia computacional y viabilidad práctica.

El capítulo 4 expone las conclusiones principales del trabajo, las limitaciones identificadas y las posibles líneas futuras de investigación.

Finalmente, los últimos apartados incluyen un glosario de términos, la bibliografía utilizada y los anexos complementarios del proyecto.

1.10. Declaración sobre el uso de inteligencia artificial generativa

El uso de herramientas de inteligencia artificial generativa en este TFG se ha realizado de forma consensuada con el tutor del trabajo. En concreto, se han empleado ChatGPT 5.5, Gemini 3.1 y el autocompletado de código de GitHub Copilot como herramientas de apoyo durante distintas fases del desarrollo.

Estas herramientas se han utilizado para ampliar el conjunto de variables de dominio del enfoque tabular, generar o adaptar código para la elaboración de gráficos y apoyar tareas de programación mediante autocompletado, además de resolver problemas técnicos concretos. Entre ellos, destacan la compatibilidad de la librería *BorutaShap* y un error de *TSFEL* que generaba variables con nombres duplicados. También se han empleado como apoyo parcial en la definición de parámetros para la extracción de variables basadas en la Transformada Continua Wavelet y en características de audio, como *MFCC* y *LPCC*.

Además, se han utilizado para revisar y mejorar la redacción de la memoria a partir de borradores previos. Esta revisión se ha centrado principalmente en la claridad expositiva y la corrección formal del texto.

En conjunto, la IA generativa ha tenido un papel auxiliar en tareas de programación, documentación y mejora formal. La definición del planteamiento metodológico, la gran parte de la implementación, la interpretación de resultados y la versión final del trabajo se encuadran en un desarrollo propio.

2. Materiales y métodos

El desarrollo experimental de este trabajo se basa en dos aproximaciones: una estrategia tabular sustentada en ingeniería de características y una estrategia de aprendizaje profundo aplicada directamente sobre las series temporales.

Dado que ambos enfoques difieren en el preprocesamiento, representación de los datos y metodología de entrenamiento, este capítulo se organiza en tres bloques. Primero, se presenta la fuente de datos y el análisis exploratorio realizado. Después, se define el marco metodológico común, incluyendo las decisiones de limpieza, evaluación y selección del umbral. Finalmente, se describen por separado los enfoques (tabulares y temporales) para facilitar la comparación entre ambas estrategias.

2.1 Fuente de datos

Los datos utilizados en este trabajo proceden de *SGCC (State Grid Corporation of China)*, la empresa de servicios públicos más grande del mundo y responsable del suministro eléctrico de aproximadamente el 88% del territorio chino en el año 2020 ^[19]. La elección de este conjunto de datos se justifica por tres motivos principales:

En primer lugar, se trata de una base de datos ampliamente utilizada en la literatura sobre detección de fraude eléctrico ^[6, 8, 9, 10, 12-18]. Esto permite situar los resultados obtenidos en un marco comparativo y contrastarlos con propuestas previas del estado del arte.

En segundo lugar, su carácter abierto favorece la reproducibilidad del trabajo. A diferencia de otros estudios basados en datos privados de distribuidoras, el uso de una fuente accesible permite documentar de forma transparente las decisiones de preprocesamiento, modelado y evaluación, facilitando la validación externa. Además, es fácilmente accesible a través del repositorio en [GitHub](#) publicado por Zheng et al. (2018) ^[9].

Por último, el conjunto de datos dispone de un volumen suficientemente amplio de clientes y casos etiquetados como fraude, lo que permite abordar la evaluación de resultados de una forma más robusta.

2.2. Análisis exploratorio de datos (EDA)

El conjunto inicial contiene 42,372 clientes y 1,034 registros diarios de consumo, comprendidos entre el 1 de enero de 2014 y el 31 de octubre de 2016, además de un identificador de cliente y la variable objetivo. Las fechas se encuentran ordenadas cronológicamente y cada fila corresponde a un cliente único. No se detectan valores negativos ni columnas no numéricas en las variables de consumo.

Tras eliminar el identificador de cliente, se identifican 873 registros duplicados. Estos apenas contienen información útil, ya que todos sus valores son nulos o cero salvo 4

lecturas positivas sobre 902,682 posibles. Puesto que no aportan información y son un grave riesgo de *data leakage*, se prescinde de estos valores.

Después de esta limpieza inicial, la distribución de clases queda formada por 37,897 clientes no fraudulentos y 3,602 clientes fraudulentos, lo que supone una proporción de fraude del 8.7%.

Como primera aproximación visual, se analiza la evolución del consumo por clase agregada por media y mediana. La *Figura 2* muestra que los clientes etiquetados como fraude presentan consumos superiores a los clientes no fraudulentos. También se observa una distancia notable entre media y mediana en ambas clases, lo que anticipa la presencia de valores extremos. En términos temporales, la variación semanal es reducida, mientras que sí se aprecia una tendencia anual creciente y cierta estacionalidad con aumentos de consumo durante los meses de verano. Estas diferencias son especialmente acusadas en el grupo fraudulento.




Figura 2. Consumo agregado por clase y tiempo.

(i) Valores sospechosos: distribución, impacto y significado

Los valores nulos y cero son especialmente relevantes en este problema porque pueden estar asociados a modificaciones o alteraciones en los aparatos de lectura. Por ello, antes de definir su tratamiento, se analiza su distribución, relación con la clase objetivo y el posible impacto sobre el modelado.

La *Figura 3* muestra una distribución desigual de los valores ausentes: mientras una parte importante de los clientes presenta pocos nulos, también aparece un grupo amplio con porcentajes cercanos al 70%. Los valores cero, por el contrario, se concentran mayoritariamente en proporciones bajas.




Figura 3. Distribución de nulos y ceros.

Profundizando en estos valores, se identifican 1,243 clientes compuestos únicamente por combinaciones de nulos y ceros, de los cuales, solo 23 se clasifican como fraude. Desde una perspectiva operativa, es poco probable que se trate de clientes activos (dados de baja, puntos de suministro desactivados, etc.), por lo que no serían auditados. Incluirlos en el proceso de modelización introduciría un patrón predictivo trivial y poco informativo: *Energía total 0 = No fraude*. Si bien incluir estos casos mejoraría artificialmente las métricas finales, no lo haría la capacidad real del modelo para distinguir el fraude entre los clientes activos. Por ello, se prescinde de estas muestras.

Seguidamente, se compara la proporción de estos valores agregados por clase. Como muestra la Figura 4, los valores ausentes son notoriamente más frecuentes en clientes fraudulentos, especialmente en la zona superior de la distribución. Esto constituye un primer indicio de que los nulos podrían no responder únicamente a fallos aleatorios de medición, sino estar relacionados con el propio fenómeno de fraude (*Missing Not At Random, MNAR*). En cambio, los valores cero se distribuyen similarmente en ambas clases, por lo que su frecuencia simple no parece ser un elemento discriminativo fuerte.




Figura 4. Distribución de nulos y ceros por clase.

Para comprobar si los ceros podrían ser informativos en forma de periodos continuados sin consumo, se analiza la racha máxima de ceros consecutivos por cliente. En la Figura 5, la densidad y distribución de estas rachas es muy similar para ambos grupos. Además, al repetir el análisis empleando la media de rachas a cero, se observarán resultados igualmente equivalentes. Esto descarta un patrón discriminatorio tan simple.




Figura 5. Distribución de rachas de ceros por cliente y clase.

A continuación, se analiza el significado temporal de los valores ausentes. Una parte considerable de los nulos se debe a entradas tardías en el registro. Por ejemplo, un 31% de los clientes no presenta datos antes del 1 de junio de 2014. Este hecho obliga a diferenciar entre nulos previos a la existencia del registro y nulos internos entre lecturas válidas.

Para descartar que estas ausencias reflejen salidas del registro tras la detección del fraude (*data leakage*), se comprueba que solo un 0.36% de toda la muestra no contiene datos después del último mes existente (septiembre de 2016). Descartando una regla de negocio de expulsión asociada al fraude.

En consecuencia, se distinguen dos tipos de nulos: los derivados de la inexistencia del registro y los internos que sí pueden interpretarse como desconexiones potencialmente informativas.

(ii) Análisis de las desconexiones

La *Figura 6* muestra que la mayoría de desconexiones son breves: aproximadamente el 92% de las rachas sin registro dura menos de 10 días. Sin embargo, usar esto como criterio para la aceptación de muestras para el modelado supondría descartar una parte relevante de los clientes.




Figura 6. Desconexiones y rachas de desconexiones.

Como se observa en la *Tabla 4*, el porcentaje de fraude entre los clientes con desconexiones más prolongadas no es despreciable (partiendo de 8.7%), lo que refuerza la idea de que estas desconexiones no deben tratarse como una simple inconsistencia. Su distribución resulta coherente con el carácter no aleatorio de los valores ausentes, en línea con la hipótesis *MNAR* planteada anteriormente.

Umbral máx. de nulos consecutivos	Total Eliminado	Total Eliminado que es Fraude
5	42%	11%
105	17%	14%
305	8%	15%
605	2%	12%

Tabla 4. Impacto muestral en caso de filtrar clientes por rachas nulas.

(iii) Valores atípicos

En detección de fraude, los valores extremos no pueden corregirse o tratarse como errores de forma automática, ya que pueden representar comportamientos anómalos informativos. Para comprender su influencia, se consideran tres métricas agregadas de consumo: máximo, promedio (sin usar nulos) y consumo total. Su combinación permite detectar valores extremos desde perspectivas distintas y teniendo en cuenta la posible influencia de los nulos.

La *Tabla 5* muestra que eliminar clientes mediante reglas basadas en el rango intercuartílico provocaría una pérdida importante de casos fraudulentos. Incluso con umbrales amplios, la proporción de fraude eliminado sigue siendo relevante. Esto indica que los consumos extremos están asociados al fenómeno estudiado y, por tanto, no deben descartarse o transformarse de forma generalizada.

Factor	Consumo total	Consumo promedio	Consumo máximo	Cualquiera
1.5	15%	17%	21%	25%
3	9%	10%	13%	15%
10	4%	4%	6%	6%

Tabla 5. Proporción de fraude con *outliers*: $IQR \cdot Factor$.

No obstante, la *Figura 7* constata la existencia de picos de consumo puntuales y desproporcionados que sí parecen corresponder a errores de lectura o registro. Así como al menos, un cliente industrial. Por ello, el preprocesamiento posterior no elimina los valores extremos en conjunto, sino únicamente los casos claramente incompatibles con el comportamiento residencial esperado.




Figura 7. Clientes con consumo diario superior a 10,000.

(iv) Análisis de los componentes

Para profundizar en la estructura temporal del consumo, se aplica una descomposición *STL* (*Seasonal-Trend decomposition using LOESS*), que separa la serie en tendencia, estacionalidad y componente irregular (residuos) mediante suavizados locales [20]. Este análisis permite comprobar si las diferencias entre clases se limitan al nivel agregado de consumo o también a patrones temporales más complejos.




Figura 8. Descomposición *STL* agregado por mediana y clase, periodo = 365.




Figura 9. Descomposición *STL* agregado por mediana y clase, periodo = 30.




Figura 10. Descomposición *STL* agregado por mediana y clase, periodo = 7.

Las *Figuras 8, 9 y 10* muestran diferencias relevantes entre clientes fraudulentos y no fraudulentos en las distintas escalas analizadas. En el componente de tendencia, el grupo fraudulento parte de consumos superiores y presenta una evolución más creciente y ondulante, mientras que el consumo legítimo se mantiene más estable. En la componente estacional, ambos grupos reflejan ciclos temporales, pero el fraude muestra oscilaciones de mayor amplitud y menor regularidad, especialmente en periodos cortos. Esto sugiere una pérdida de estabilidad en los hábitos de consumo a corto plazo.

El componente irregular también resulta especialmente informativo. En los clientes no fraudulentos, el residuo es reducido y cercano a cero, lo que indica que buena parte de su consumo puede explicarse mediante los componentes de tendencia y estacionalidad. En cambio, en los clientes fraudulentos, el residuo es más variable y presenta cambios abruptos, compatibles con alteraciones no explicadas por el calendario ni por patrones de consumo regulares.

En conjunto, el análisis indica que el fraude no se caracteriza únicamente por un mayor nivel de consumo, sino también por una estructura temporal menos estable y menos predecible. Esta evidencia justifica la extracción de variables tabulares orientadas a capturar la tendencia, la variabilidad, los cambios bruscos, la magnitud y la estacionalidad. Asimismo, respalda la necesidad de considerar características capaces de capturar patrones temporales en distintas escalas, desde variaciones locales de corto plazo hasta cambios estructurales más prolongados.

(v) Autocorrelación y estacionariedad

Tras analizar los componentes temporales, se estudia la autocorrelación estructural de las series. A priori, un consumo eléctrico regular debería mantener cierta dependencia con sus retardos más recientes, de modo que las lecturas de días próximos tiendan a parecerse entre sí. Para medir esta relación se utiliza la Función de Autocorrelación (ACF).

La *Figura 11* muestra el vector promedio de autocorrelaciones para 2,000 muestras por clase. Ambas mantienen una dependencia temporal positiva incluso con retardos de hasta 60 días. De forma sorprendente, estos valores son más altos en las series fraudulentas, lo que sugiere una mayor persistencia temporal. La diferencia entre clases aparece desde los primeros retardos y se mantiene a lo largo del periodo analizado.




Figura 11. ACF media por clase.

Complementariamente, se evalúa la estacionariedad de las series entendida como la estabilidad de sus propiedades estadísticas —media, varianza y autocorrelación— a lo largo del tiempo [20]. Para ello, se emplea el test Dickey-Fuller aumentado (ADF).

Los resultados del test sobre 1,000 muestras aleatorias por clase revelan que aproximadamente el 61% de las series legítimas pueden considerarse estacionarias, frente al 49% de las fraudulentas. Esto sugiere que las segundas presentan, con mayor frecuencia, consumos inestables o cambios estructurales a largo plazo. No obstante, la diferencia no es extrema, por lo que la estacionariedad por sí sola no parece un factor discriminante fuerte.

En suma, la ACF indica que el fraude mantiene una dependencia temporal local, mientras que los resultados del *STL* y del *ADF* apuntan a una mayor inestabilidad global, dado que las series fraudulentas combinan persistencia temporal con cambios estructurales e irregularidades más pronunciadas.

(vi) Perfiles de consumo

Finalmente, se realiza una agrupación exploratoria mediante K-Means para identificar perfiles generales de consumo y comprobar si el fraude se concentra en patrones concretos. Para ello, se emplean ocho variables agregadas: media, desviación típica, coeficiente de variación, tres percentiles y ratios de picos y caídas. Tras estandarizar las variables y mitigar el efecto de los valores extremos, el método del codo sugiere utilizar $k = 4$.

Los grupos obtenidos muestran que el fraude no responde a un único perfil de consumo. Una parte importante de los clientes fraudulentos aparece en perfiles de bajo consumo, mientras que las mayores tasas de fraude se concentran en grupos de baja frecuencia, caracterizados por consumos intermedios o altos, presencia de picos y mayor dispersión entre cuantiles. También aparece un perfil de consumo muy bajo pero inestable, con una proporción de fraude similar a la del conjunto original.

En definitiva, este análisis confirma que el fraude eléctrico no puede identificarse mediante estadísticas simples basadas únicamente en el valor de consumo, lo que refuerza la necesidad de crear un número elevado de predictores variados para el enfoque tabular.

2.3. Preprocesamiento compartido

A partir del análisis exploratorio anterior, se definen las decisiones de limpieza comunes en los dos enfoques de modelado. En esta sección solo se recogen las acciones compartidas, ya que el enfoque tabular y el temporal requieren tratamientos específicos posteriores, especialmente en la imputación de nulos y en la representación de las series.

Acción	Justificación
Inconsistencia	
Eliminación de 1,243 clientes inactivos (solo nulos y ceros), más otros 873 registros duplicados carentes de información.	Se ha comprobado que no son fuente de fraude. No contienen información. Se evita <i>data leakage</i> y el consecuente incremento artificial de métricas.
Eliminación de muestras irregulares extremas: clientes que en 3 años no tienen 60 días de registro consecutivo.	El impacto es nimio (0.14%). Un periodo inferior a 2 meses puede ser volátil, sesgado y no representativo.
Valores nulos	
Eliminación de clientes con 670 nulos consecutivos.	Casos muy extremos y residuales (0.21%), con una estructura temporal prácticamente inexistente, lo que dificulta la extracción de patrones fiables.
Evaluación experimental de un umbral alternativo de 250 nulos consecutivos.	Permite comprobar si una limpieza más estricta mejora el rendimiento, aunque reduce la representatividad al eliminar el 9.69% de la muestra. Este perjuicio operativo tan solo se justificaría por un aumento drástico del rendimiento.
Outliers	

Se elimina a 1 cliente industrial.	En la <i>Figura 7</i> , en color naranja, hay un cliente que consume en el mismo plazo de tiempo, la misma electricidad que 1,400 clientes aleatorios. Se descarta por ser un cliente industrial o un simple error.
Se sustituyen los errores de lectura (<i>outliers</i> desproporcionadamente extremos) por nulos y se interpola linealmente. <i>Nota: se aplica en momentos distintos según el pipeline.</i>	Para mantener la información relevante de valores extremos, se aplican varios filtros para asegurar que solo se modifican los errores de lectura: • (i) Identificar valores por el percentil >0.99 • (ii) Que dicho valor sea 3 veces su percentil 0.95 • (iii) Además, debe ser superior a 100

Tabla 6. Preprocesamiento compartido.

En conjunto, el preprocesamiento busca eliminar únicamente inconsistencias claras o casos sin información suficiente, evitando descartar patrones potencialmente asociados al fraude. Por ello, no se aplica una limpieza agresiva de nulos, desconexiones u *outliers*, ya que estos elementos pueden formar parte del comportamiento que el modelo debe aprender.

2.4. Marco general de evaluación

Para evaluar los modelos de forma consistente, se utiliza una partición estratificada del conjunto de datos en entrenamiento, validación y test, con proporciones 70%, 15% y 15%, respectivamente. La estratificación permite que la proporción de fraude se mantenga constante en los tres subconjuntos, evitando que las métricas dependan de diferencias artificiales en la distribución de clases.

El conjunto de entrenamiento se emplea para ajustar los modelos, mientras que el conjunto de validación se reserva para comparar configuraciones, seleccionar hiperparámetros, evaluar decisiones de preprocesamiento y optimizar el umbral de clasificación. Por este motivo, se mantiene un conjunto de validación suficientemente amplio, capaz de ofrecer estimaciones estables en un problema desbalanceado. Finalmente, el conjunto de test se utiliza exclusivamente para la evaluación final del rendimiento.

Tras la partición, los tres subconjuntos mantienen una proporción de fraude del 8.76%; con 28,072 clientes en entrenamiento; 6,016 en validación y 6,016 en test.

Una vez definida la partición de los datos, es necesario establecer el marco metodológico bajo el cual se juzgará el rendimiento de ambas alternativas. Al tratarse de un problema de clasificación desbalanceado con implicaciones operativas, la evaluación no debe basarse únicamente en el acierto global, sino también en métricas específicas por clase.

2.4.1. Impacto del error predictivo y métricas seleccionadas

En un sistema de detección de fraude eléctrico, los errores del modelo tienen consecuencias distintas según el actor afectado.

- Consumidor legítimo
Su prioridad es evitar inspecciones innecesarias, comunicaciones incómodas o sanciones injustas. Aunque también se beneficia de una elevada tasa de detección, dado que el coste de la energía defraudada puede repercutir sobre

el conjunto de usuarios. Su principal riesgo es ser clasificado erróneamente como sospechoso.

- **Negocio (distribuidora)**

Busca reducir los costes operativos asociados a inspecciones improductivas derivadas de falsas alarmas, así como mitigar el deterioro de su imagen corporativa. Al mismo tiempo, detectar el mayor volumen posible de fraude permite recuperar ingresos directos y favorecer servicios secundarios como el alquiler de contadores o seguros.

Por tanto, el problema no puede evaluarse únicamente mediante métricas globales de acierto. Es necesario distinguir entre falsos positivos y falsos negativos, así como valorar el equilibrio entre detección de fraude y fiabilidad de las alertas generadas. Para ello, se emplean métricas derivadas de la matriz de confusión, dependientes del umbral de clasificación.

Métrica	Fórmula	Significado
Precisión	$\frac{VP}{VP+FP}$	De las predicciones positivas, cuántas realmente lo son. Rango [0, 1].
Recall	$\frac{VP}{VP+FN}$	Tasa de detección. Rango [0, 1].
F1-score	$2 \cdot \frac{Precisión \cdot Recall}{Precisión + Recall}$	Equilibrio entre Precisión y Recall. Rango [0, 1].
MCC	$\frac{VP \cdot VN - FP \cdot FN}{\sqrt{(VP + FP)(VP + FN)(VN + FP)(VN + FN)}}$	Rango [-1, 1]. 1 indica predicción perfecta, 0 ausencia de correlación entre predicción y realidad, y valores negativos una asociación inversa.

Tabla 7. Métricas de error.

Tal y como señalan Chicco y Jurman (2020), el MCC resulta especialmente relevante en problemas desbalanceados, ya que solo alcanza valores elevados cuando el modelo obtiene un buen comportamiento en todas las categorías de la matriz de confusión [21].

No obstante, las métricas anteriores dependen de la elección final del umbral de decisión. Por ello, durante el desarrollo, también se emplean métricas de separabilidad que evalúan la capacidad del modelo para ordenar correctamente las clases a lo largo de todos los posibles umbrales.

Métrica	Fórmula	Significado
ROC-AUC	$\int_0^1 TVP(u) d(TFP(u))$ Siendo las tasas de VP y FP: $TVP(u) = \frac{VP(u)}{VP(u) + FN(u)}$ $TFP(u) = \frac{FP(u)}{FP(u) + VN(u)}$	Mide la capacidad global del modelo para separar las clases. Compromiso entre TVP y TFP en todos los umbrales. Rango [0, 1]. 1 indica separación perfecta; 0.5 comportamiento aleatorio.

<i>PR-AUC</i>	$\int_0^1 \text{Precisión}(r) d(\text{Recall}(r))$	Mide la separabilidad enfocada en la clase positiva. Evalúa el equilibrio entre precisión y <i>recall</i> , especialmente útil en problemas desbalanceados. Rango [0, 1]. 1 indica rendimiento perfecto.
---------------	--	--

Tabla 8. Métricas de separabilidad.

En este trabajo, *ROC-AUC* y *PR-AUC* se utilizan para comparar la capacidad potencial de los modelos y guiar las decisiones de desarrollo. Dado el desbalance de clases, la *PR-AUC* adquiere especial relevancia al centrarse en el comportamiento sobre la clase positiva. Las métricas de error, en cambio, se interpretan tras fijar un umbral de decisión, ya que permiten valorar el impacto operativo de las predicciones finales.

2.4.2. Optimización del umbral de decisión

En un entorno operativo real, el umbral de clasificación podría definirse a partir de variables como el coste de una inspección, el coste estimado del fraude no detectado o la capacidad máxima de revisión. Sin embargo, al no disponer de esta información, se adopta un criterio ético-operativo orientado a equilibrar la fiabilidad de las alertas y el rendimiento.

Concretamente, el umbral se selecciona maximizando el *MCC* sobre el conjunto de validación, pero imponiendo una precisión mínima de 0.55. Esta restricción evita un sistema excesivamente ruidoso, donde una parte elevada de las alertas corresponde a consumidores legítimos. Al mismo tiempo, el uso del *MCC* permite mantener una visión equilibrada del conjunto de la matriz de confusión, evitando optimizar únicamente la precisión a costa de una pérdida desproporcionada de *recall*.

Una vez fijado el umbral en validación, se aplica sin modificaciones sobre el conjunto de test, reservado exclusivamente para la evaluación final.

2.5. Enfoque tabular

El enfoque tabular consiste en transformar cada serie temporal de consumo en un conjunto de variables explicativas que sintetizan distintos aspectos de su comportamiento. Esta representación reduce la dimensionalidad de la señal original y permite aplicar modelos de aprendizaje automático especialmente eficaces sobre datos estructurados.

En la literatura revisada, algunos trabajos utilizan directamente los consumos diarios como variables de entrada [7, 10], mientras que otros parten de conjuntos de datos que ya contienen variables agregadas [11]. También existen propuestas que extraen características de las series temporales mediante librerías especializadas, como *TSFEL* o *Catch22* [12, 15]. En este trabajo se sigue esta última línea, pero ampliando de forma considerable el espacio de características generado.

Concretamente, se construyen distintas versiones del conjunto tabular que contienen entre 160 y 247 variables, combinando características automáticas y variables diseñadas manualmente. El objetivo no es solo asumir de antemano qué patrones serán discriminativos, sino generar una representación suficientemente amplia de las series para que el proceso de selección posterior identifique qué información aporta valor predictivo real.

Dado el elevado número de variables y la posible presencia de ruido o redundancia, la selección de características se trata como un aspecto central del enfoque tabular y se describe específicamente en el apartado 2.5.3.

Para el modelado, se emplean algoritmos basados en *tree ensembles*, concretamente *XGBoost*, *LightGBM* y *CatBoost*. Esta elección se justifica por su buen rendimiento en problemas tabulares de alta dimensionalidad, su capacidad para capturar relaciones no lineales y su eficiencia computacional. En la misma línea, Borisov et al. (2024) señalan que estos modelos continúan superando con frecuencia a las arquitecturas profundas en datos tabulares, con tiempos de entrenamiento significativamente inferiores [22].

Finalmente, se evalúan tanto modelos individuales como estrategias de ensamblado, con el objetivo de comprobar si la combinación de algoritmos y distintos espacios de características permiten mejorar el rendimiento predictivo frente a las soluciones individuales.

2.5.1. Extracción de características tabulares

Para construir el *dataset* final, se generan hasta ocho variantes tabulares organizadas en dos grupos, según el límite máximo de desconexiones consecutivas aceptado. Dentro de cada grupo, se modifica el número de ventanas temporales empleadas para extraer características, lo que permite comparar distintos niveles de detalle.

Esta estrategia permite evaluar, mediante métricas de separabilidad, dos aspectos clave: el grado de complejidad o detalle óptimo y el equilibrio entre rendimiento e inclusión de un porcentaje superior de muestras. El flujo completo de extracción se resume en la *Figura 12*, donde se observa cómo el proceso combina distintas transformaciones según los requisitos de cálculo de cada bloque de características.




Figura 12. Extracción de características.

En primer lugar, se aplican las decisiones de limpieza comunes descritas en el *apartado 2.3*: eliminación de muestras sin información, registros duplicados, clientes sin al menos 60 días consecutivos de consumo, cliente industrial y casos extremos de desconexión. El conjunto con un máximo de 670 desconexiones consecutivas actúa como base, mientras que la variante más restrictiva, limitada a 250, se filtra a partir de este.

A continuación, el proceso se bifurca según la necesidad de imputar valores nulos. En el flujo superior, se evita la imputación, ya que algunas variables dependen directamente de la presencia de nulos y otras podrían verse artificialmente sesgadas por una reconstrucción excesiva del consumo. Esta decisión resulta especialmente relevante dado el elevado volumen de valores ausentes. En esta rama se diferencian cuatro bloques de extracción:

1. Variables operativas del negocio: relacionadas con los índices temporales como la entrada al registro o la antigüedad del cliente.
2. Variables de consumo sospechoso: descriptores asociados a valores nulos y ceros, como rachas máximas, ratios o centro de masa.
3. Variables estacionales: características basadas en la fecha, como la tendencia interanual, los picos en verano o las diferencias mensuales.
4. Variables estrictas de consumo: tratan el consumo como un vector temporal, incluyendo medidas como entropía, conteo de valles, asimetría o estadísticos de distribución.

La mayoría se calculan sobre la serie completa, aunque otras se obtienen mediante ventanas deslizantes sin solapamiento (división de la serie en tramos). Estas ventanas permiten aumentar el detalle de la representación y comparar cambios internos de la serie —como la diferencia de consumo medio entre ventanas— manteniendo el orden cronológico, sin depender directamente de fechas. Este bloque es el que determina el número final de características en las variantes que emplean particiones de 2, 4, 8 o 12 ventanas.

En el flujo inferior de la *Figura 12*, se aplica una extracción automática mediante *TSFEL*, que permite obtener variables estadísticas, temporales, espectrales y fractales [23]. Dado que esta librería no admite valores nulos, previamente se aplica una estrategia específica de imputación que se encuentra resumida en la *Tabla 9*.

Imputación de	Justificación
Desconexiones ≤ 7 días mediante interpolación lineal.	Elimina el 90% de los nulos sin introducir sesgos artificiales.
Desconexiones > 7 días usando la mediana mensual del cliente. En su defecto, mediana global.	Asegura que la imputación de periodos prolongados respete la estacionalidad (reconocidas fluctuaciones en verano) y mantenga los niveles de escala reales del usuario, minimizando la generación de artefactos matemáticos.
Series inferiores a 180 días utilizando el primer y último valor de forma simétrica (<i>padding</i>).	Las muestras afectadas son $\leq 1\%$. Algunas características requieren establecer particiones o rangos. Utilizar el valor mínimo (60 días) fuerza un nivel de detalle extremo para la mayoría de clientes con $> 1,000$ días.

Tabla 9. Imputación de nulos para *TSFEL*.

Antes de unir ambas ramas, se eliminan las variables constantes generadas por *TSFEL* y se aplica un filtro de correlación de Pearson superior a 0.95. Con ello se reduce la redundancia extrema entre variables, manteniendo la diversidad de

representaciones sin introducir una pérdida significativa de información. Este filtrado evita almacenar 84 variables. Tras unir la extracción automática con la extracción manual, se aplica de nuevo el filtro de correlación sobre el conjunto resultante.

Finalmente, en cada variante se añade una puntuación de anomalía obtenida con *Isolation Forest*, entrenado únicamente sobre los datos de entrenamiento. Este valor indica cuán atípico es el comportamiento de cada cliente en el conjunto de variables, y permite al modelo supervisado explotar esa señal como indicador de fraude.

2.5.2. Elección del conjunto óptimo

Una vez generadas las ocho variantes tabulares, se comparan para seleccionar el conjunto que servirá como base en las fases posteriores de selección de características, *resampling* y optimización. Esta evaluación se realiza únicamente sobre el conjunto de entrenamiento mediante validación cruzada estratificada de 5 *folds*, evitando utilizar el conjunto de validación en una fase todavía exploratoria del *pipeline*.

La comparación se lleva a cabo con cada uno de los tres modelos propuestos: *LightGBM*, *XGBoost* y *CatBoost*. En todos los casos se emplea una configuración estable y no optimizada, con ponderación del desbalance entre clases, profundidad moderada y estrategias de submuestreo de filas y columnas. De este modo, la evaluación no busca maximizar el rendimiento final, sino comparar de forma homogénea la calidad predictiva de cada representación tabular. Para ello, se utilizan métricas independientes del umbral de clasificación, concretamente *PR-AUC* y *ROC-AUC*.

Nº Ventanas	Nº Características	Media <i>PR-AUC</i>	Media <i>ROC-AUC</i>
Desconexiones: 250			
12	247	0.549	0.863
2	161	0.547	0.862
8	214	0.546	0.863
4	180	0.538	0.862
Desconexiones: 670			
2	160	0.531	0.862
4	180	0.531	0.864
8	214	0.531	0.865
12	247	0.529	0.865

Tabla 10. Elección del dataset final.
En negrita la mejor métrica por desconexiones.

Los resultados muestran que las variantes más restrictivas, limitadas a un máximo de 250 desconexiones consecutivas, alcanzan valores ligeramente superiores de *PR-AUC*. Sin embargo, la mejora respecto a las variantes con 670 desconexiones es reducida, mientras que la *ROC-AUC* se mantiene prácticamente estable. Por tanto,

una limpieza más agresiva no parece aportar una ganancia predictiva suficiente para compensar la pérdida de representatividad del 9.48%.

En cuanto al número de ventanas temporales, las diferencias entre 2, 4, 8 y 12 ventanas son pequeñas y no muestran una mejora sistemática al aumentar la granularidad. Por este motivo, se selecciona como conjunto óptimo la variante con un máximo de 670 desconexiones consecutivas y 4 ventanas temporales. Esta configuración mantiene una mayor cobertura muestral, incorpora suficiente detalle temporal y evita aumentar innecesariamente la dimensionalidad. El conjunto resultante suma 180 características.

2.5.3. Selección de características

Partiendo de un conjunto de 180 variables (algunas de ellas altamente relacionadas entre sí), resulta necesario aplicar un método de selección de características que permita reducir ruido y redundancia, mitigar el riesgo de sobreajuste y facilitar la interpretabilidad de los modelos posteriores. Con este objetivo se emplea *BorutaSHAP*, una variante del algoritmo *Boruta* publicada en GitHub por Eoghan Keany (2020) [24].

(i) ¿Qué es *Boruta*?

El algoritmo *Boruta*, por Kursu et al. (2010) [25] crea copias (*shadow attributes*) de todas las variables y las permuta aleatoriamente para eliminar su correlación con la variable objetivo. Al entrenar un *Random Forest*, se extrae la importancia (en Z-scores) de todas las características. La importancia máxima obtenida entre los atributos *shadow* (MZSA) se fija como umbral de referencia. Las variables originales que superan este umbral en cada iteración anotan un acierto (*hit*). Mediante un test estadístico sobre el acumulado de *hits*, se evalúa si la importancia de cada variable es significativamente superior al azar (clasificándola como importante) o inferior (descartándola). Este bucle se repite hasta clasificar todas las variables o alcanzar el límite fijado.




Figura 13. Diagrama *Boruta*.

(ii) Valores *SHAP*

Los valores *SHAP* (*SHapley Additive exPlanations*) [26] son un método de explicabilidad que asigna a cada variable su contribución a la predicción de una observación concreta. Estos valores se calculan evaluando la contribución marginal de cada variable en todos los posibles subconjuntos de variables, manteniendo el modelo fijo. Al promediar el valor absoluto de estas contribuciones locales en todo el conjunto de datos, se obtiene una medida global y justa de la relevancia de cada variable.

(iii) *BorutaSHAP*

Combinando ambos conceptos surge *BorutaSHAP*. El método sigue la estrategia iterativa de *Boruta*, pero sustituye la importancia basada en *Random Forest* por valores *SHAP* como medida de relevancia. Esto permite una estimación más precisa de la contribución de cada variable, lo que resulta especialmente útil cuando el espacio de características es amplio y contiene variables redundantes o correlacionadas.

Además, puede emplearse directamente con los modelos del *pipeline* final, manteniendo la coherencia entre la selección de variables y el modelo evaluado.

(iv) Experimentación previa

Para validar el método, se aplicó *BorutaSHAP* sobre el primer conjunto de características (161 variables), entrenando un modelo poco profundo mediante validación cruzada estratificada de 3 *folds*. Como se observa en la *Figura 14*, tras eliminar 115 variables, se mantiene una capacidad predictiva equivalente, con una pérdida de 0.02 en *PR-AUC*. Mientras, la pérdida en *ROC-AUC* es nula.




Figura 14. *BorutaSHAP* en *LightGBM*, prueba de rendimiento en validación. RFECV solo para ilustrar.

(v) Implementación

La aplicación de *BortuaSHAP* se realiza únicamente sobre el conjunto de entrenamiento y de forma independiente para cada modelo. Se utilizan 50 iteraciones, se aceptan las variables tentativas y se fija un p-valor de 0.1, priorizando una selección permisiva que evite descartar señales débiles, pero potencialmente útiles.

Cada modelo se configura con un enfoque exploratorio ¹, es decir, con una profundidad limitada, *bagging* de filas y columnas. De este modo, se favorece la conservación de características que muestran utilidad bajo distintas condiciones de aleatoriedad, aunque no sean siempre dominantes. Finalmente, se obtienen 50 variables en *LightGBM*, 49 en *XGBoost* y 55 en *CatBoost*.

2.5.4. Estrategias *resampling*

Una vez reducido el espacio de características, se evalúa la posible incorporación de estrategias de *resampling* para tratar el desbalance entre clases. Esta decisión se analiza en esta fase para evitar aplicar técnicas de generación o eliminación de muestras sobre un espacio de variables excesivamente amplio y redundante. Además, como demuestran Barua et al. (*MWMOTE*, 2014) ^[27] y Mahmoudi et al. (*DSMOTE*, 2014) ^[28], el impacto de estos métodos depende en gran medida del conjunto de datos, por lo que su utilidad debe comprobarse empíricamente.

La evaluación se realiza con modelos base estables, siguiendo el planteamiento anterior para seleccionar el conjunto óptimo de características (2.5.2). Para ello, se utiliza validación cruzada estratificada con 5 *folds* sobre el conjunto de entrenamiento y

se comparan los resultados en validación. Los métodos considerados cubren tres grupos principales: *oversampling*, *undersampling* y métodos híbridos, y aprendizaje sensible al coste (*cost-sensitive learning*) mediante pesos nativos.

(i) *Oversampling*: algoritmos de frontera y *clustering*

Como técnica base de *oversampling* se emplea *SMOTE*, que genera nuevas observaciones interpolando cada instancia minoritaria con uno de sus k vecinos más cercanos elegidos aleatoriamente. A partir de este enfoque, se evalúan variantes orientadas a mejorar la localización de las muestras sintéticas. *ADASYN* y *Borderline-SMOTE* concentran la generación de ejemplos en observaciones minoritarias difíciles de clasificar, cercanas a la frontera de decisión. Por su parte, *K-Means SMOTE* agrupa previamente los datos para reducir la generación de muestras en zonas dominadas por patrones legítimos y focalizar el sobremuestreo en regiones más representativas del fraude.




Figura 15. Ejemplo ilustrativo: métodos *oversampling*.

(ii) *Undersampling e hybrid resampling*

También se consideran métodos híbridos, ya que generar muestras artificiales en zonas de alto solapamiento puede introducir ruido y degradar la precisión del modelo. En este grupo se evalúan *SMOTE-ENN* y *SMOTE-Tomek*, que combinan el sobremuestreo de la clase minoritaria con una fase posterior de limpieza basada en reglas de vecindad. Como alternativa de *undersampling* se incluye *NearMiss-v3*, que retiene clientes legítimos próximos a la frontera de decisión y descarta ejemplos mayoritarios más alejados.




Figura 16. Ejemplo ilustrativo: métodos *hybrid resampling* y *NearMiss-v3*.

(iii) Pesos nativos (*cost-sensitive learning*)

Finalmente, se evalúa el uso de pesos nativos de los algoritmos como alternativa de *cost-sensitive learning*. A diferencia del *resampling*, este enfoque no modifica la distribución original de los datos, sino que penaliza de forma asimétrica los errores cometidos sobre la clase minoritaria durante el entrenamiento.

(iv) Resultados

Los resultados, visibles en la Figura 17, muestran que las variantes de *oversampling* y los métodos híbridos reducen de forma consistente la *PR-AUC* (entre 3 y 6 puntos) respecto a la línea base. Esto indica que, en este conjunto de datos, la generación de muestras artificiales introduce más ruido que información útil para definir la frontera de decisión. El submuestreo mediante *NearMiss-v3* presenta un deterioro todavía mayor, lo que sugiere que eliminar registros de la clase mayoritaria alejados de la frontera destruye información relevante para distinguir correctamente los patrones legítimos.




Figura 17. Evaluación de estrategias *resampling*.

En cambio, las estrategias basadas en pesos nativos obtienen los mejores resultados globales, manteniendo valores superiores y muy similares entre sí en *PR-AUC* y *ROC-AUC*. En consecuencia, se descartan las técnicas de *resampling*. El tratamiento del desbalance se aborda exclusivamente mediante el balance de pesos propio de cada algoritmo.

2.5.5. Optimización de hiperparámetros

En la elección de hiperparámetros, se ha utilizado el algoritmo *TPE* (*Tree-structured Parzen Estimator*) mediante la librería *Optuna*. Este método probabilístico aprende de iteraciones (*trials*) pasadas, separando las configuraciones que dieron buenos resultados — $l(x)$ — de las peores — $g(x)$ —, y utiliza esta información para guiar la búsqueda hacia valores con mayor probabilidad de mejorar el modelo, a partir del ratio $\frac{l(x)}{g(x)}$ [29]. De este modo, se explora el espacio de hiperparámetros de forma más eficiente que enfoques exhaustivos como *Grid Search*.

La optimización se aplica de forma individualizada en los tres modelos. En todos los casos, el objetivo es maximizar la *PR-AUC*, al tratarse de una métrica especialmente adecuada para comparar modelos en un problema desbalanceado y centrada en la clase positiva. Para evitar ajustar los hiperparámetros sobre el conjunto de validación final, la búsqueda se realiza mediante validación cruzada estratificada de 3 *folds* exclusivamente sobre el conjunto de entrenamiento.

Con el fin de equilibrar el rendimiento y el coste computacional, cada modelo se entrena con un número elevado de iteraciones con *early stopping* para detener el entrenamiento cuando no se observan mejoras. Además, se utiliza el mecanismo *Median Pruner* de *Optuna*, que descarta anticipadamente aquellos *trials* cuyo rendimiento intermedio es inferior a la mediana de los ensayos anteriores.

El espacio de búsqueda incluye hiperparámetros relacionados con la complejidad estructural del modelo, como la profundidad máxima, el número de hojas o el tamaño mínimo de los nodos; parámetros de aprendizaje, como el *learning rate*; mecanismos

de regularización L1/L2; estrategias de aleatoriedad y muestreo de filas o columnas; además del peso asignado a la clase minoritaria. El detalle completo de los rangos explorados se recoge en el anexo ².

Resultados de la optimización

Los resultados muestran una mejora moderada, pero consistente tras la optimización. En la *Tabla 11*, se observa que los tres modelos incrementan su *PR-AUC* respecto a la configuración base, destacando *XGBoost* ³ como el modelo tabular con mejor rendimiento en validación.

Algoritmo	<i>PR-AUC</i> (Base)	<i>PR-AUC</i> (Optimizado)	Mejora
<i>LightGBM</i>	0.539	0.554	+ 0.015
<i>XGBoost</i>	0.540	0.562	+ 0.022
<i>CatBoost</i>	0.526	0.555	+ 0.029

Tabla 11. Comparativa de rendimiento tras la optimización de hiperparámetros.
En negrita el mayor *PR-AUC* optimizado y máxima mejora.

2.6. Enfoque profundo sobre series temporales

El segundo bloque metodológico evalúa si una arquitectura de aprendizaje profundo aplicada directamente sobre las series temporales puede aportar una ventaja frente al enfoque tabular. Mientras que la estrategia anterior resume a cada cliente mediante variables agregadas, este enfoque conserva la secuencia diaria completa y permite que el modelo aprenda patrones discriminativos directamente desde la señal original.

Para ello, se opta por una arquitectura basada en Redes Neuronales Convolucionales Unidimensionales (CNN 1D). Este tipo de redes procesa la secuencia mediante filtros convolucionales aplicados de forma paralela, lo que permite identificar con agilidad patrones locales repetitivos, picos, caídas bruscas y anomalías temporales en la señal ^[30]. Esta propiedad resulta especialmente adecuada para el presente problema, ya que el análisis exploratorio ha mostrado que el fraude no se caracteriza únicamente por diferencias globales de consumo, sino también por irregularidades, cambios de nivel, alteraciones de la estabilidad temporal y comportamientos no explicados por la tendencia o la estacionalidad.

Además, el uso de convoluciones evita depender de un procesamiento estrictamente recurrente. Esto resulta relevante en secuencias largas como las utilizadas en este trabajo, compuestas por más de 1,000 lecturas diarias, donde las arquitecturas recurrentes pueden presentar dificultades para mantener dependencias prolongadas, un mayor coste de entrenamiento y problemas asociados a la propagación del gradiente ^[31]. Por ello, la CNN 1D se plantea como una alternativa eficiente y coherente con la estructura temporal del problema.

No obstante, una única escala temporal puede resultar insuficiente para capturar la diversidad de patrones observados. Algunas señales de fraude pueden manifestarse en variaciones locales, como picos o caídas puntuales, mientras que otras pueden aparecer como cambios más prolongados en la tendencia, la estacionalidad o la estabilidad del consumo. Por este motivo, se diseña una arquitectura convolucional multiescala, capaz de analizar simultáneamente la serie mediante *kernels* de distinto tamaño temporal.

2.6.1. Preprocesamiento de la señal temporal

Para garantizar una comparativa equitativa con el enfoque tabular, se aplica el mismo preprocesamiento general descrito en el apartado 2.3. Sobre esta base, se interpolan linealmente las desconexiones cortas de hasta 7 días, lo que permite resolver el 90% de los valores ausentes sin introducir sesgos artificiales. A continuación, se limitan los valores de consumo (*clipping*) a los percentiles 0.01 y 0.99 para reducir el impacto de valores atípicos más extremos que pueden desestabilizar el entrenamiento de la red.

Con los datos limpios, se procede a estandarizar la señal de consumo. Para evitar que los valores nulos distorsionen la distribución, la media y la desviación típica se calculan ignorando los valores nulos. Además, ambos parámetros se estiman exclusivamente sobre el conjunto de entrenamiento y se aplican después a validación y test, evitando así cualquier fuga de información.

Por último, siguiendo la estrategia de Farid et al. (2023) [8], se genera una máscara binaria que identifica los días sin registro. Esta decisión responde a la naturaleza *MNAR* de los datos, planteada en el *EDA* y reforzada posteriormente por la elevada importancia predictiva asignada por *BorutaSHAP* a las variables derivadas de los nulos. Los valores ausentes restantes se sustituyen por ceros —equivalentes a la media tras la estandarización, pero diferenciados por la máscara— y, finalmente, se construye el tensor tridimensional de entrada a la red con dimensiones $muestras \times timesteps \times 2 \text{ canales}$. Un canal para el consumo y otro para la máscara.

2.6.2. Diseño de la arquitectura base

Sobre esta representación de dos canales, el bloque principal de extracción se compone de cuatro ramas convolucionales paralelas con *kernels* de 7, 31, 91 y 365 días. Estos tamaños permiten capturar patrones semanales, mensuales, trimestrales y anuales, respectivamente. Las salidas de las cuatro ramas se concatenan y se procesan mediante una segunda capa convolucional, que permite integrar las representaciones extraídas en cada escala y aprender interacciones locales entre ellas.

Tras la extracción convolucional, se combinan dos operaciones de agregación global: *GlobalAveragePooling1D* y *GlobalMaxPooling1D*. La primera sintetiza la activación media de cada filtro a lo largo de la serie, mientras que la segunda conserva su activación máxima. Esta combinación permite representar tanto patrones sostenidos en el tiempo como activaciones extremas puntuales, coherentemente con el *EDA*, donde se observaron diferencias entre clases en la magnitud, la tendencia y la presencia de valores extremos.

Finalmente, el modelo incorpora una capa densa con regularización mediante *Dropout*, y se entrena con la función de pérdida *binary crossentropy*. La métrica monitorizada durante el entrenamiento es la *PR-AUC*, por su mayor adecuación a un problema desbalanceado y centrado en la detección de la clase fraudulenta.

2.6.3. Estrategia experimental de diseño

Antes de fijar la arquitectura definitiva, se realizan varias pruebas exploratorias sobre el conjunto de validación. Estas pruebas no tienen como objetivo estimar el rendimiento final del modelo, sino comparar decisiones de diseño y descartar variantes que no aporten mejoras claras.

La comparación se basa principalmente en la *PR-AUC* de validación, acompañada de la *ROC-AUC* como métrica complementaria de separabilidad. Además, se revisan las

curvas de *loss* y *PR-AUC* en entrenamiento y validación para comprobar la estabilidad del aprendizaje y detectar señales de sobreajuste. Durante estas pruebas, se emplean mecanismos habituales de entrenamiento como *early stopping* y la reducción adaptativa de la tasa de aprendizaje.

Las variantes evaluadas se agrupan en dos bloques. En primer lugar, se analizan modificaciones sobre la arquitectura base y la representación de los datos: uso de pesos de clase, incremento de regularización, reducción temporal mediante *downsampling* (agregación semanal) y filtrado más estricto de muestras. En segundo lugar, se estudia la incorporación de atención temporal, primero como sustituto del *pooling* global y posteriormente como componente adicional dentro de una arquitectura híbrida.

2.6.4. Selección de la arquitectura final

En la primera iteración, la arquitectura base obtiene el mejor comportamiento inicial. La incorporación de pesos de clase no mejora la separación entre clases, mientras que el incremento de regularización y el uso de *downsampling* reducen las *PR-AUC* y *ROC-AUC* de validación. Esto sugiere que la red no presentaba un problema claro de sobreajuste y que la reducción temporal de la señal elimina información local útil para la clasificación.

También se evalúa la variante más consistente del conjunto de datos, limitando las desconexiones consecutivas máximas a 250 días en lugar de 670. Aunque esta alternativa produce series aparentemente más consistentes, sus resultados son peores, reduciendo la *PR-AUC* en -0.07. Por tanto, no se justifica eliminar estas muestras y se confirma de nuevo que las desconexiones prolongadas no actúan únicamente como ruido, sino como rasgos parcialmente constitutivos del patrón conductual asociado al fraude.

En una segunda iteración, se introduce un mecanismo de atención temporal para mejorar la interpretabilidad del modelo. La atención asigna un peso a cada instante temporal y genera una representación agregada mediante una suma ponderada de la secuencia. Sin embargo, al sustituir completamente las capas de *pooling*, el rendimiento cae de forma notable. Esta pérdida resulta coherente con el análisis exploratorio, donde el fraude aparece como un fenómeno heterogéneo: valores extremos en algunos clientes, cambios de tendencia, variabilidad o estabilidad sostenida, irregularidades locales, etc. Por ello, una agregación basada únicamente en atención puede resultar insuficiente, al no conservar la información persistente capturada por el *pooling*.

Por este motivo, la arquitectura final combina ambos enfoques. Se mantienen *GlobalAveragePooling1D* y *GlobalMaxPooling1D* para conservar la capacidad de síntesis global y la sensibilidad a activaciones extremas, y se añade en paralelo un bloque de atención temporal que pondera los distintos tramos de la serie según su relevancia. La concatenación de estos tres vectores permite integrar en una misma representación la información agregada de la serie, los eventos de mayor intensidad y la localización temporal de los patrones más relevantes.




Figura 18. Arquitectura MSCNN-AT.

Esta arquitectura híbrida, *MSCNN-AT* (*Multi-Scale CNN with Attention*), se selecciona como solución final del bloque temporal, ya que mejora levemente el rendimiento en validación de la *CNN* multiescala base e incorpora un componente adicional de interpretabilidad temporal.

2.6.5. Configuración final de entrenamiento

La configuración final se fija a partir de las iteraciones anteriores y de pruebas manuales sobre validación. Debido al coste computacional de una búsqueda automática extensa, no se aplica una optimización exhaustiva de hiperparámetros como en el enfoque tabular. En su lugar, se prioriza una configuración estable, sin *downsampling* y sin pesos de clase, ya que estas variantes tampoco mejoraron el rendimiento de la arquitectura *MSCNN-AT* durante la fase experimental.

Parámetro	Valor final
Filtros por rama convolucional	32
Unidades densas	64
<i>SpatialDropout1D</i>	0.2
<i>Dropout</i> (capa densa)	0.5
Regularización L2	1e-4
<i>Downsampling</i> temporal	No

<i>Learning rate</i>	1e-3
Peso clase fraude	1.0
Épocas máximas	60
<i>Batch size</i>	128

Tabla 12. *MSCNN-AT*, hiperparámetros de entrenamiento.

3. Resultados

En este capítulo se presentan los resultados obtenidos por las dos estrategias predictivas desarrolladas. La comparación no se limita a las métricas de separabilidad, sino que incorpora también el impacto operativo de los errores, la estabilidad de los modelos, la interpretabilidad y la viabilidad práctica de cada solución.

3.1. Consideraciones metodológicas sobre la evaluación

Antes de analizar los resultados, conviene señalar una diferencia importante en la forma de evaluar ambos enfoques. El modelo *MSCNN-AT* trabaja directamente sobre la señal temporal, por lo que puede evaluarse mediante validación cruzada con distintas particiones de entrenamiento, validación y test. En este caso, se aplican 5 *folds* con submuestreo aleatorio, lo que permite comprobar la capacidad de generalización del modelo ante distribuciones distintas de clientes y casos fraudulentos.

En cambio, replicar esta misma estrategia en el enfoque tabular habría requerido repetir en cada *fold* todo el proceso de selección de variables con *BorutaSHAP* y la optimización de hiperparámetros con *Optuna*. Además de su elevado coste computacional, esto habría generado distintos espacios de características en cada iteración, dificultando la comparación directa entre modelos.

Por este motivo, en el enfoque tabular se mantiene fijo el espacio de variables seleccionado y se repite el entrenamiento con distintas semillas. Así, la variabilidad reportada refleja principalmente la estabilidad del modelo ante cambios en la inicialización y en los procesos internos de muestreo de filas y columnas, mientras que en *MSCNN-AT* la variabilidad incorpora también el efecto de trabajar con particiones distintas de los datos.

3.2. Resultados del enfoque tabular

Tras la extracción y selección de características, se entrenan los modelos individuales y se evalúa la posibilidad de combinarlos mediante estrategias de ensamblado. El *soft voting* propuesto combina los modelos promediando sus probabilidades de salida, mientras que el *stacking* entrena un meta-modelo adicional —en este caso, una regresión logística— para aprender cómo ponderar y combinar sus predicciones.

La *Tabla 13* recoge las métricas de error obtenidas sobre el conjunto de test una vez aplicado el umbral operativo definido en validación.

Algoritmo	<i>MCC</i>	<i>F1</i> Macro	<i>Recall</i> Fraude	Precisión Fraude	<i>Recall</i> Legítimo	Precisión Legítimo
<i>LightGBM</i>	0.451 ±0.01	0.724 ±0	0.46 ±0.02	0.535 ±0.02	0.961 ±0	0.949 ±0
<i>XGBoost</i>	0.464 ±0	0.728 ±0	0.446 ±0.04	0.575 ±0.05	0.967 ±0	0.948 ±0
<i>CatBoost</i>	0.462 ±0.01	0.729 ±0	0.459 ±0.03	0.557 ±0.05	0.964 ±0.01	0.949 ±0
<i>Stacking</i>	0.464	0.732	0.505	0.516	0.955	0.953
<i>Soft Voting</i>	0.462	0.731	0.488	0.528	0.958	0.951

Tabla 13. Enfoque tabular: métricas de error.
En negrita la mejor métrica.

Los tres modelos individuales muestran un rendimiento muy similar. *XGBoost* obtiene el mejor equilibrio operativo, con el *MCC* más alto junto a *stacking* (0.464) y la mayor precisión sobre la clase fraude (0.575), aunque con un *recall* ligeramente inferior al de *CatBoost* y *LightGBM*. Esta diferencia resulta relevante porque, en un contexto real, la precisión determina qué proporción de inspecciones se dirige a clientes fraudulentos.

Las estrategias de ensamblado aumentan el *recall* hasta valores cercanos al 50%, pero lo hacen reduciendo la precisión. En consecuencia, detectan una proporción algo mayor de fraude, pero a costa de incrementar el número de inspecciones sobre clientes legítimos. Además, su uso dificultaría la interpretabilidad del sistema, al combinar varios modelos y reducir la claridad con la que pueden justificarse las predicciones.

Llevado a un escenario de 1,000 inspecciones, *XGBoost* permitiría identificar aproximadamente 47 fraudes adicionales respecto al *soft voting* y, al mismo tiempo, evitaría otras 47 inspecciones improductivas. Por tanto, aunque los ensamblados parecen competitivos en términos agregados, no aportan una mejora práctica suficiente frente al mejor modelo individual.

Por estos motivos, *XGBoost* se selecciona como modelo final del enfoque tabular. Además de obtener el mejor *MCC* junto a *stacking*, es el modelo que mantiene con mayor consistencia la precisión mínima planteada inicialmente, superando el umbral de 0.55 en 4 de las 5 semillas. Esto lo convierte en la alternativa más adecuada para priorizar inspecciones fiables, manteniendo una solución más interpretable y sencilla de desplegar que las estrategias ensambladas.

3.3. Resultados del enfoque profundo temporal y comparativa

Las métricas de error obtenidas por *MSCNN-AT* son superiores a las del enfoque tabular. Como muestra la *Tabla 14*, el modelo alcanza un *MCC* de 0.595 ± 0.01 , frente al 0.464 de *XGBoost*, y mejora especialmente la precisión sobre la clase fraude, que pasa de 0.575 a 0.767.

	<i>MCC</i>	<i>F1</i> Macro	<i>Recall</i> Fraude	Precisión Fraude	<i>Recall</i> Legítimo	Precisión Legítimo
<i>MSCNN-AT</i>	0.595 ± 0.01	0.789 ± 0.01	0.509 ± 0.06	0.767 ± 0.05	0.984 ± 0.01	0.954 ± 0
Mejora sobre <i>XGBoost</i>	+0.13	+0.06	+0.06	+0.19	+0.02	+0.01

Tabla 14. Métricas de error *MSCNN-AT*.

La mejora en *recall* es más moderada (+0.06), por lo que la principal ventaja del modelo no es solo detectar más fraude, sino reducir significativamente el número de inspecciones fallidas. Esto se refleja también en el *recall* de la clase legítima, que alcanza 0.984 ± 0.01 .

Con el fin de comparar los modelos sin depender de un único umbral de decisión, se representa la curva Precisión-Recall sobre la misma semilla y partición.




Figura 19. Curva Precisión-Recall, misma semilla única y partición.

Como se observa en la figura anterior, los modelos tabulares presentan un comportamiento prácticamente indistinguible entre sí. En cambio, *MSCNN-AT* se sitúa por encima de ellos a lo largo de toda la curva (excepto extremos), ampliando las posibilidades de selección del umbral. Si se busca capturar el 60% del fraude, esta arquitectura mantiene una precisión cercana al 70%, frente a una precisión próxima al 40% alcanzada por los modelos tabulares con el mismo *recall*. En un escenario más conservador, detectando el 40% del fraude, *MSCNN-AT* alcanza una precisión cercana al 90%.

Por tanto, *MSCNN-AT* no supone una mejora marginal, sino que amplía considerablemente el rango operativo del sistema. La extracción automática de patrones temporales mediante convoluciones multiescala, *pooling* mixto y atención permite aprovechar información que no queda suficientemente representada en las

variables tabulares. En consecuencia, esta arquitectura se establece como el modelo con mejor rendimiento predictivo del trabajo.

3.4. Comparativa con el estado del arte

Para situar los modelos desarrollados dentro del *SOTA*, se utiliza la métrica *ROC-AUC*, al ser el indicador reportado de forma más consistente en la literatura revisada.




Figura 20. Comparativa *SOTA*: *ROC-AUC*.

Como se observa en la *Figura 20*, ambos enfoques propuestos superan la línea base de Bohani et al. [10], siendo además este el único trabajo que reporta métricas adicionales como precisión y *recall*. En particular, *XGBoost* alcanza un *ROC-AUC* de 0.865, por encima de arquitecturas profundas especializadas como *Wide-Deep-CNN* [9] (0.800) y *NearMiss-TCN-MLP* [6] (0.850). Este resultado evidencia que una ingeniería de características adecuada puede competir e incluso superar modelos profundos basados directamente en series temporales.

Por su parte, *MSCNN-AT* obtiene un *ROC-AUC* de 0.907, situándose entre los mejores resultados identificados en la literatura. Si bien *CNN+STN* [8] reporta un valor ligeramente superior (0.920), esta comparación debe interpretarse con cautela. Dicha evaluación mantiene 2,116 muestras prácticamente no informativas, incluyendo 1,243 clientes compuestos únicamente por valores nulos o cero —de los cuales 1,220 pertenecen a «no fraude»—, así como 873 registros duplicados con contenido mínimo. La presencia de estas observaciones simplifica la tarea de clasificación y puede favorecer artificialmente el rendimiento reportado.

Además, los propios autores reconocen valores modestos de precisión, sin aportar valores concretos. En contraste, *MSCNN-AT* mantiene no solo un *ROC-AUC* competitivo, sino también una *PR-AUC* de 0.684 ± 0.01 entre las particiones evaluadas.

En conjunto, los resultados sitúan a *MSCNN-AT* como una propuesta competitiva dentro del *SOTA*, con una evaluación más exigente al excluir registros triviales o duplicados y al incorporar métricas más informativas para un problema desbalanceado de detección de fraude eléctrico.

3.5. Explicabilidad de los modelos

Como se expone en los objetivos y en la justificación ética del trabajo, la capacidad predictiva no es suficiente por sí sola en un sistema de detección de fraude eléctrico. Una predicción debe poder revisarse, justificarse y, en última instancia, ser validada por una persona antes de derivar en una inspección.

Por este motivo, se analizan los mecanismos de explicabilidad de los dos modelos principales: *XGBoost*, como mejor solución tabular, y *MSCNN-AT*, como arquitectura con mejor rendimiento global. El objetivo no es solo identificar qué modelo predice mejor, sino valorar qué tipo de explicación ofrece cada enfoque y hasta qué punto esta puede ser útil para el operario o en una auditoría.

3.5.1. Explicabilidad en el enfoque tabular (*XGBoost*)

Los modelos basados en árboles ofrecen una interpretabilidad más directa que las arquitecturas profundas, especialmente cuando trabajan sobre variables previamente definidas. En este caso, la explicación de *XGBoost* se complementa con valores *SHAP*, que permiten analizar tanto la importancia global de las variables como su contribución en predicciones individuales.

(i) Explicabilidad Global

En primer lugar, se analizan las importancias nativas de *XGBoost* mediante las métricas de ganancia y cobertura. La ganancia representa la mejora de exactitud que aporta una característica a las ramas en las que se encuentra, mientras que la cobertura aproxima cuántos clientes se ven afectados por dichas particiones. No se emplea la importancia basada en frecuencia de uso, ya que el *bagging* de variables introducido en los hiperparámetros reparte artificial y uniformemente su uso.




Figura 21. Importancias nativas de *XGBoost*.

Las importancias nativas muestran un peso destacado de *plateau_type*, variable asociada a tramos de consumo plano. Esta característica es la que más contribuye a reducir el error y también una de las que afecta a más observaciones. Junto a ella, aparecen variables relacionadas con la dispersión temporal del consumo, como *winter_std*, *w4_spread* (rango del último tramo registrado) o *0_Spectral_variation*.

También destacan varias variables derivadas de valores nulos, como los cambios de consumo antes y después de una desconexión (*nulls_abs_step_change_mean*), la posición temporal de los nulos (*idx_ratio*) o las rachas de valores ausentes (*streaks*). Este resultado refuerza la hipótesis planteada en el análisis exploratorio: las desconexiones no parecen responder únicamente a fallos aleatorios de medición, sino que contienen información útil para detectar patrones compatibles con fraude.

No obstante, las importancias nativas solo indican qué variables utiliza el modelo, pero no cómo influyen en la predicción. Para estudiar la dirección y magnitud de estos efectos se analizan los valores *SHAP*.




Figura 22. Importancia *SHAP* Bar (izquierda) y *SHAP* Beeswarm (derecha).

Desde esta perspectiva, *winter_std* y *nan_start_prob* aparecen como las variables más determinantes. El gráfico *Beeswarm* permite observar que valores altos de variación anual (*annual_cv*), una tendencia creciente del consumo y valores bajos de *plateau_type* empujan la predicción hacia la clase fraude. En cambio, una variación espectral elevada (*0_Spectral_variation*) se interpreta como un comportamiento irregular, pero más asociado a clientes legítimos.

El papel de los nulos es especialmente relevante. Las rachas largas de valores ausentes y una alta probabilidad de transición hacia nulo no se asocian necesariamente a fraude, sino que el modelo parece interpretarlas como posibles problemas estructurales de registro. En cambio, un aumento marcado del consumo tras una desconexión sí actúa como señal sospechosa. Esto matiza la hipótesis inicial: los nulos importan, pero no por su mera presencia, sino por el contexto temporal en el que aparecen y por cómo cambia el consumo alrededor de ellos.

(ii) Explicabilidad local

Además de los patrones generales, en un escenario real es necesario justificar predicciones concretas. Para ello, los valores *SHAP* permiten descomponer cada decisión mediante gráficos de cascada (*waterfall*), mostrando qué variables empujan la predicción hacia fraude y cuáles la desplazan en sentido contrario.




Figura 23. Gráficos *SHAP* Waterfall: verdadero positivo (izquierda) y falso positivo (derecha).

En el ejemplo de verdadero positivo, el modelo combina varias señales coherentes: rachas medias de nulos (`nulls_mean_consecutive`) algo elevadas, una tendencia global muy creciente (`cons_global_trend_slope`), un rango de consumo extremo en la última ventana (`w4_spread`) y un número de picos y valles de consumo en mínimos globales. Aunque existen factores que reducen la probabilidad de fraude, como la menor antigüedad del cliente, el balance final justifica la clasificación positiva.

El falso positivo muestra un caso distinto. La alarma se activa por una variabilidad muy elevada: desviación típica inusual extrema, distribución de ceros desplazada hacia el tramo final de la serie, rango de consumo desproporcionadamente alto en la última ventana, y aumento notable del consumo tras valores nulos. En este caso, el modelo detecta un patrón anómalo, pero no necesariamente fraudulento. Esta lectura es útil porque permite entender el error: no se trata de una decisión arbitraria, sino de un cliente con rasgos estadísticamente parecidos a los casos de fraude.

En conjunto, *XGBoost* ofrece explicaciones claras y auditables, tanto a nivel global como individual. Su principal ventaja es que permite identificar qué variables sustentan cada decisión. Sin embargo, esta claridad tiene un límite. Al trabajar sobre características agregadas, se pierde parte de la resolución temporal original. El modelo explica qué patrón ha sido relevante, pero no muestra con precisión cuándo aparece dentro del consumo histórico.

3.5.2. Explicabilidad en el enfoque temporal (*MSCNN-AT*)

Aunque las redes neuronales convolucionales suelen considerarse modelos de baja interpretabilidad, *MSCNN-AT* incorpora una capa de atención temporal que permite proyectar parte de la explicación sobre la serie original de consumo. Esto no convierte al modelo en plenamente transparente, pero sí ayuda a identificar qué periodos del histórico reciben mayor peso y qué tramos resultan más sensibles para la predicción.

(i) Explicabilidad global

En primer lugar, se analiza el peso medio de atención asignado a cada mes entre los clientes fraudulentos del conjunto de test. Este análisis permite comprobar si la red concentra sistemáticamente su atención en determinadas épocas del año o si, por el contrario, distribuye el foco de forma más homogénea.




Figura 24. Atención promedio mensual en clientes fraudulentos.

La *Figura 24* muestra una distribución relativamente uniforme, con valores mensuales que oscilan aproximadamente entre el 7.5% y el 10.5%. Esto indica que el modelo no basa la detección en una estación concreta, sino en patrones que pueden aparecer en distintos momentos del año.

Este resultado es coherente con el análisis exploratorio previo. Aunque el consumo legítimo presenta cierta estacionalidad, especialmente en verano, el fraude no parece depender únicamente del calendario. La red aprende a identificar alteraciones en la forma de la serie más que aumentos o caídas asociados a un mes específico.

(ii) Explicabilidad local

Para el análisis de casos concretos, los pesos de atención ayudan a revelar en qué momentos de la serie temporal se fija el modelo.




Figura 25. Explicabilidad local por atención temporal.

El análisis de los tres casos revela que la atención no reacciona ante la magnitud absoluta del consumo ni ante anomalías puntuales, sino ante dos tipos de tramos concretos: los cambios bruscos de nivel sostenido y los periodos de volatilidad extrema prolongada (falso positivo). Por el contrario, los pesos de atención decaen en periodos de variación estacional regular y en tramos de consumo prolongadamente planos, donde el modelo no detecta ruptura conductual alguna.

No obstante, dado que la arquitectura actual emplea el mecanismo de atención en paralelo a capas de *pooling* mixto, los pesos de atención solo ofrecen una explicabilidad parcial sobre el contexto temporal. Para medir qué tramos son realmente determinantes en la decisión final, se aplica la técnica de sensibilidad por oclusión, que sustituye periodos de consumo por un valor base y cuantifica el impacto sobre la probabilidad de salida.




Figura 26. Sensibilidad por oclusión, ventanas de 30 y 7 días.

Al ocluir periodos prolongados (un mes), se observa que la confianza del clasificador se desploma con una caída de probabilidad superior a 0.6. Esto sucede al ocultar la zona de mayor inestabilidad y consumos extremos. En contraste, ocultar el episodio anómalo de finales de 2015 produce una caída moderada, probablemente, insuficiente para cambiar la clasificación. Concluyendo que el modelo fundamenta la decisión principalmente en episodios prolongados de alta magnitud y varianza.

Con una ventana semanal, la caída máxima de probabilidad es apenas del 0.03. El modelo penaliza principalmente los eventos extremos puntuales aunque su impacto en la decisión final es mínimo.

En suma, mientras que el enfoque tabular detalla de forma exhaustiva el «qué» (propiedades matemáticas que definen la anomalía), el enfoque temporal permite explicar el «cuándo» y el «dónde» (tramos específicos del consumo sospechoso). Desde una perspectiva estrictamente operativa, la explicabilidad temporal de la *MSCNN-AT* resulta especialmente intuitiva, ya que recrea visualmente el mismo ejercicio de revisión gráfica que llevaría a cabo un analista humano.

3.6. Productos obtenidos y viabilidad

Tras completar el desarrollo de ambas metodologías, el resultado final es un repositorio de código que documenta cada paso del proceso, incluyendo los productos principales: los propios modelos entrenados.

Como se ha mencionado, este proyecto tiene un claro enfoque operativo, por lo que es necesario valorar si las ventajas de *MSCNN-AT* justifican su mayor coste computacional.




Figura 27. Tiempo de entreno e inferencia en distintos entornos.

En cuanto al entrenamiento, *XGBoost* converge en 14 segundos de media en un equipo local, mientras que *MSCNN-AT* requiere unos 7 minutos en la nube, unas 28 veces más. Aun así, este tiempo sigue siendo insignificante dadas las consecuencias prácticas de su aplicación.

Respecto a la inferencia, en un entorno sin aceleración por *GPU*, *MSCNN-AT* es 61 veces más lento que *XGBoost*. En términos absolutos, esto se traduce en aproximadamente 1 minuto para procesar 100,000 clientes, frente al segundo que requeriría *XGBoost*. Un tiempo perfectamente viable para su aplicación sobre carteras de clientes diarias, incluso en equipos con recursos limitados.

4. Conclusiones y trabajos futuros

Este último capítulo sintetiza los hallazgos más relevantes obtenidos durante la fase de experimentación. Asimismo, se exponen las limitaciones técnicas identificadas en los modelos y se proponen nuevas líneas de investigación para dar continuidad al proyecto.

4.1. Conclusiones principales del trabajo

Este TFG ha desarrollado y comparado dos enfoques metodológicos para la detección de fraude eléctrico sobre el dataset SGCC.

En el enfoque tabular se ha combinado extracción automática de características con variables diseñadas a partir del *EDA*, generando conjuntos de entre 160 y 247 características. Mediante *BorutaSHAP*, se ha reducido a aproximadamente 50 variables manteniendo el rendimiento del conjunto completo. Se han evaluado tres modelos de *tree ensembles* —con resultados individuales muy similares entre sí— y dos estrategias de ensamblado (*soft voting* y *stacking*), sin que estas últimas aportaran mejoras determinantes. El mejor modelo individual, *XGBoost*, obtiene un *ROC-AUC* de 0.865, una *PR-AUC* de 0.545 y un *MCC* de 0.464.

En el enfoque temporal se ha implementado la arquitectura *MSCNN-AT*, que procesa las series de consumo mediante ramas convolucionales paralelas con *kernels* de

distintas escalas temporales, seguidas de una capa de fusión convolucional y un mecanismo de agregación que combina *average pooling*, *max pooling* y *attention*. Obtiene un *ROC-AUC* de 0.907, una *PR-AUC* de 0.684 y un *MCC* de 0.595.

Ambos enfoques superan la línea base de la literatura y sitúan este trabajo dentro del *SOTA*. En este contexto, *XGBoost* supera arquitecturas profundas especializadas como *Wide-Deep-CNN* (AUC 0.8) y *NearMiss-TCN-MLP* (AUC 0.85), evidenciando que una ingeniería de características adecuada puede competir con modelos profundos sobre series temporales. *MSCNN-AT*, por su parte, se sitúa entre los mejores resultados reportados, con una evaluación más exigente y métricas más informativas para un problema desbalanceado.

La conclusión principal es que *MSCNN-AT* es el mejor modelo para este problema bajo cualquier umbral de decisión. Frente a *XGBoost*, mejora en precisión fraude (+0.19), *MCC* (+0.13) y *F1* Macro (+0.06), redefiniendo las posibilidades operativas: captura hasta un 40% del fraude con un 90% de precisión, frente a una precisión cercana al 65% con la misma tasa de detección en *XGBoost*.

En cuanto a la viabilidad operativa, se han considerado dos aspectos adicionales.

- Explicabilidad: *XGBoost* ofrece interpretabilidad más transparente, pero pierde resolución temporal por la naturaleza estadística de sus características; *MSCNN-AT*, en cambio, señala directamente cuándo y dónde ocurre la anomalía sobre la curva de consumo, un formato más intuitivo para el supervisor humano pero menos transparente.
- Coste computacional: aunque la red requiere más tiempo de entrenamiento (7 minutos frente a 14 segundos), su inferencia sigue siendo completamente viable —1 minuto para 100.000 clientes sin aceleración por *GPU*—, lo que hace irrelevante este coste frente a la mejora en detección.

4.2. Limitaciones del modelo

Durante el análisis, se ha observado una drástica caída en la frecuencia de valores nulos a principios de 2016.




Figura 28. Distribución temporal de valores nulos.

Dado que los modelos (especialmente el tabular) han aprendido a apoyarse fuertemente en estos patrones de desconexión, su capacidad predictiva podría degradarse en escenarios futuros donde este comportamiento cambie. Esto los hace altamente eficaces para la base de datos actual, pero requerirán de actualizaciones y reentrenamientos periódicos para mitigar el *concept drift*.

Esta dependencia hacia los patrones de nulos dificulta también la extrapolación directa a otros sistemas eléctricos. No obstante, como se argumentó en la introducción, esto es inherente al problema: cada red eléctrica presenta comportamientos y anomalías radicalmente distintos, lo que requiere modelos adaptados a su contexto local.

Por otro lado, *MSCNN-AT* presenta una dependencia del contexto temporal largo. Al eliminar el *kernel* de escala anual (365 días), el rendimiento del modelo decae hasta niveles similares al enfoque tabular, lo que sugiere que gran parte de su capacidad discriminativa reside en la detección de patrones a largo plazo. Esto puede dificultar su aplicación en escenarios donde no se disponga de un historial suficientemente extenso.

4.3. Objetivos, seguimiento de la metodología y riesgos

Se han alcanzado la totalidad de los objetivos generales y específicos planteados al inicio de la memoria. Se ha desarrollado una solución transparente (OG1). Se ha comparado exitosamente la estrategia tabular frente a la temporal (OG2) y se han superado por amplia diferencia las métricas base de la literatura (OE4). Así como el resto de objetivos necesarios para sustentar la metodología (OE1, OE2 y OE3).

Con todo, ha sido necesario adaptar la planificación y afrontar ciertos riesgos técnicos.

(i) Tiempos y selección de características

La extracción tabular tomó 8 días frente a los 4 planificados debido a la complejidad del patrón de fraude. Además, se descartó el método de selección de características inicial *RFECV* por sobreajustarse a la validación, adoptando *BorutaSHAP* para filtrar el ruido de forma más robusta.

(ii) Riesgos de reproducibilidad

La ejecución de *BorutaSHAP* no es estrictamente determinista; las variaciones de 1 o 2 centésimas entre ejecuciones pueden alterar levemente qué modelo tabular resulta mejor. Igualmente, en el enfoque temporal, a pesar de configurar la estrategia determinista más estricta de *TensorFlow* ^[32], no se ha logrado una reproducibilidad exacta. La evaluación mediante remuestreo con reemplazo hace que estos resultados fluctúen algunas centésimas más entre iteraciones.

(iii) Recursos y entregables

Para afrontar la carga computacional, se ha hecho uso del presupuesto de contingencia para *Google Colab*. Por último, el repositorio adjunto incluye la versión final evaluada junto con los *scripts* de las gráficas y correcciones menores de redacción.

4.4. Impacto ético, social y de sostenibilidad

Desde el punto de vista ético, el trabajo presenta un riesgo reducido de discriminación algorítmica debido a la naturaleza de los datos empleados. El conjunto utilizado contiene exclusivamente información de consumos eléctricos, sin incorporar variables personales sensibles como género, raza, religión o nivel socioeconómico. Por tanto, no existen evidencias directas de sesgos asociados a atributos protegidos.

Sin embargo, sí existen implicaciones relevantes derivadas del impacto de los errores de clasificación. En particular, los falsos positivos pueden provocar inspecciones innecesarias sobre clientes legítimos, generando costes administrativos, molestias o situaciones conflictivas. Por este motivo, se ha utilizado la *PR-AUC* en el diseño de ambos enfoques y se ha seleccionado un umbral suficiente para alcanzar valores razonables de precisión incluso a costa de reducir la tasa de detección.

El excelente rendimiento de la propuesta final también tiene un impacto directo sobre las ODS de justicia, sostenibilidad y el medio ambiente. Capturar a más defraudadores, evita el gasto eléctrico indiscriminado viable a través del robo. Asimismo, influye en las facturas de los clientes honestos, en la viabilidad de las inversiones de la red eléctrica y la seguridad de la propia red, favoreciendo un sistema más justo y accesible.

Desde el punto de vista ético, el modelo *MSCNN-AT* permite cierta interpretabilidad, pero puede ser insuficiente ante los casos más complejos. En un entorno real, cualquier sistema de detección de fraude debería utilizarse como herramienta de apoyo a la decisión y no como mecanismo autónomo de sanción. La supervisión humana continúa siendo indispensable. Para mitigar este riesgo, el proyecto fija una licencia no comercial.

4.5. Trabajos futuros

El desarrollo de este TFG deja abiertas prometedoras vías de investigación:

- Diseñar un sistema unificado que alimente la capa final de clasificación tanto con las representaciones profundas de la *MSCNN-AT* como con las características tabulares coincidentes en todos los modelos de *BorutaSHAP*.
- Como el *kernel* anual es crítico para el rendimiento de *MSCNN-AT*, es recomendable explorar arquitecturas o estrategias de entrenamiento que mantengan capacidad discriminativa con historiales cortos, haciendo el sistema viable para los clientes más recientes.
- Dada la reconocida influencia de los patrones a medio o largo plazo en la predicción, la evolución más natural es la experimentación con arquitecturas *Transformer* dada su capacidad para capturar dependencias a largo plazo, capacidades de explicabilidad y escalabilidad. Concretamente, la variante *Temporal Fusion Transformer* permite incluir variables estáticas con un rendimiento prometedor y, a la vez, “la interpretabilidad está en el centro de todas sus decisiones de diseño”^[33]. Haciéndolo una alternativa prioritaria.

5. Glosario

- **Data leakage (fuga de datos).** Ocurre cuando el modelo se entrena con datos que no debería tener disponibles, como información relacionada con la variable objetivo o filtración de información entre los conjuntos.
- **Pipeline.** Secuencia ordenada y reproducible de pasos aplicados a los datos, desde la limpieza y transformación inicial hasta el entrenamiento y evaluación final.
- **Ensamblado.** Estrategia de modelado que combina las predicciones de varios modelos para obtener una predicción final.
- **Bagging.** Técnica basada en introducir aleatoriedad mediante el uso de subconjuntos de muestras o variables durante el entrenamiento.
- **Tree ensembles.** Familia de modelos que combinan múltiples árboles de decisión para mejorar la capacidad predictiva frente a un árbol individual.
- **Early stopping.** Criterio de parada anticipada del entrenamiento cuando el rendimiento en validación deja de mejorar durante un número determinado de iteraciones, reduciendo el coste computacional y limitando el sobreajuste.
- **Reducción adaptativa de la tasa de aprendizaje.** Mecanismo de entrenamiento que disminuye automáticamente la tasa de aprendizaje cuando la métrica de validación deja de mejorar.
- **Shuffle.** Reordenación aleatoria de las muestras antes o durante ciertos procesos de entrenamiento o validación.
- **Estacionalidad.** Patrón temporal que se repite en un periodo fijo de forma de forma regular y predecible, por ejemplo, variaciones mensuales, semanales o anuales del consumo eléctrico.
- **Retardos.** Desplazamientos temporales utilizados para comparar una serie con sus valores pasados.
- **Ventanas deslizantes sin solapamiento:** división de una serie temporal en tramos consecutivos que no comparten observaciones entre sí.
- **Isolation Forest.** Algoritmo de detección de anomalías no supervisado que identifica observaciones atípicas midiendo la facilidad con la que pueden aislarse del resto de datos mediante particiones aleatorias sucesivas. Las anomalías requieren menos particiones para quedar aisladas, lo que se traduce en una puntuación de anomalía más alta.
- **Oversampling.** Técnicas de balanceo que aumentan la representación de la clase minoritaria en el conjunto de entrenamiento, ya sea duplicando muestras existentes o generando nuevas muestras sintéticas.
- **Undersampling.** Técnicas de balanceo que reducen la representación de la clase mayoritaria en el conjunto de entrenamiento, normalmente eliminando o seleccionando un subconjunto de sus muestras.
- **Hybrid resampling.** Estrategia que combina técnicas de *oversampling* y *undersampling*.
- **Kernels.** Tamaños de ventana utilizados por las capas convolucionales que se deslizan sobre los datos de entrada para analizar fragmentos temporales.
- **GlobalAveragePooling 1D.** Capa de agregación que resume cada filtro convolucional mediante su activación media. Reduce la dimensión, el coste computacional y ayuda a generalizar.
- **GlobalMaxPooling1D.** Capa de agregación que conserva la activación máxima de cada filtro.
- **Pooling mixto (o global).** Combinación de *GlobalAveragePooling1D* y *GlobalMaxPooling1D* dentro de la arquitectura *MSCNN-AT*.
- **Dropout.** Técnica de regularización que desactiva aleatoriamente una parte de las unidades de una capa durante el entrenamiento. Su objetivo es reducir el sobreajuste y favorecer que la red aprenda representaciones más robustas.

- **Binary crossentropy.** Función de pérdida utilizada en problemas de clasificación binaria. Mide la diferencia entre la probabilidad predicha por el modelo y la etiqueta real, penalizando las predicciones alejadas de la clase correcta.
- **Attention.** Técnica que permite a la red neuronal ponderar la relevancia de cada paso temporal de la serie antes de construir su representación final. Para cada día, una capa densa con activación *tanh* genera una puntuación de relevancia; a continuación, *softmax* normaliza esas puntuaciones para que sumen 1, obteniendo un peso por día. El vector final es una combinación ponderada de todos los días, donde los más informativos contribuyen más al resultado.
- **RFECV.** Método de selección de variables basado en la eliminación recursiva de características con validación cruzada.

6. Bibliografía

- [1] Agencia Internacional de la Energía (IEA) (2023). Disponible en: <https://www.iea.org/data-and-statistics/data-tools/energy-statistics-data-browser?country=WORLD&fuel=Electricity%20and%20heat&indicator=TotElecCons> (Consultado: 5 de mayo 2025).
- [2] World Bank (2025). Electric power transmission and distribution losses (% of output) (EG.ELC.LOSS.ZS) [base de datos]. Washington, DC: World Bank. Disponible en: <https://data.worldbank.org/indicator/EG.ELC.LOSS.ZS> (Consultado: 5 de mayo de 2026). Datos procedentes de International Energy Agency (IEA).
- [3] Comisión Nacional de los Mercados y la Competencia (2015). *Informe sobre alternativas de regulación en materia de reducción de pérdidas y tratamiento del fraude en el suministro eléctrico* (PDN/DE/001/2015). Madrid: CNMC. Disponible en: <https://www.cnmc.es/expedientes/pdn00115> (Consultado: 5 de mayo de 2026).
- [4] International Energy Agency (2023). *Electricity Grids and Secure Energy Transitions: Enhancing the foundations of resilient, sustainable and affordable power systems* (Revised version, November 2023). Paris: IEA. Disponible en: <https://www.iea.org/reports/electricity-grids-and-secure-energy-transitions> (Consultado: 5 de mayo de 2026).
- [5] Yépez-García, R. A. y Jiménez Mori, R. A. (eds.) (2024). *The economics of electricity losses in Latin America and the Caribbean*. Washington, DC: Inter-American Development Bank. Disponible en: <http://dx.doi.org/10.18235/0012971> (Consultado: 5 de mayo de 2026).
- [6] Arif, A. et al. (2022) *Towards Efficient Energy Utilization Using Big Data Analytics in Smart Cities for Electricity Theft Detection*. Big data research. [Online] 27.
- [7] Gunturi, S. K. & Sarkar, D. (2021) *Ensemble machine learning models for the detection of energy theft*. Electric power systems research. [Online] 192.
- [8] Farid, S. et al. (2023) *Electricity Theft Detection Via Deep Learning*. 2023 International Conference on Communication Technologies (ComTech). [Online] pp. 79–86.
- [9] Zheng, Z. et al. (2018) *Wide and Deep Convolutional Neural Networks for Electricity-Theft Detection to Secure Smart Grids*. IEEE transactions on industrial informatics. [Online] 14 (4), 1606–1615.
- [10] Bohani, F. A. et al. (2021) *A Comprehensive Analysis of Supervised Learning Techniques for Electricity Theft Detection* Jit S. Mandeep (ed.). Journal of Electrical and Computer Engineering. [Online] 20211–10.

- [11] Mohammad, F. et al. (2023) *Ensemble-Learning-Based Decision Support System for Energy-Theft Detection in Smart-Grid Environment*. Energies (Basel). [Online] 16 (4), 1907.
- [12] Hussain, S. et al. (2021) *A Novel Feature-Engineered–NGBoost Machine-Learning Framework for Fraud Detection in Electric Power Consumption Data*. Sensors (Basel, Switzerland). [Online] 21 (24), 8423.
- [13] Elshennawy, N. M. et al. (2025) *An efficient electricity theft detection based on deep learning: An efficient electricity theft detection based on deep learning*. Scientific reports. [Online] 15 (1), .
- [14] Kawoosa, A. I. et al. (2023) *Using machine learning ensemble method for detection of energy theft in smart meters*. IET generation, transmission & distribution. [Online] 17 (21), 4794–4809.
- [15] Bai, W. et al. (2024) *Detection Method for Three-Phase Electricity Theft Based on Multi-Dimensional Feature Extraction*. Sensors (Basel, Switzerland). [Online] 24 (18), 6057.
- [16] Pamir et al. (2023) *Electricity theft detection for energy optimization using deep learning models*. Energy science & engineering. [Online] 11 (10), 3575–3596.
- [17] Iqbal, M. S. et al. (2025) *An efficient approach for electricity theft detection based on transfer learning in temporal sequence*. Results in engineering. [Online] 26.
- [18] Kabir, B. et al. (2025) *Detecting electricity theft in smart grids using optimized machine learning ensemble techniques and eXplainable AI*. Energy reports. [Online] 143142–3162.
- [19] State Grid Corporation of China (2020) About SGID and SGCC. Disponible en: <http://www.stategrid.com.cn/html/sqiden/gb/AboutUs/AboutSGIDandSGCC/20200717/20200717104403670982900.shtml> (Consultado: 9 de mayo de 2026).
- [20] Valiente Martos, M. y Subirats Maté, L. (2026) *Modelos estadísticos y aprendizaje automático para el análisis de datos temporales*. [Recurso de aprendizaje textual]. Primera edición. Barcelona: Fundació Universitat Oberta de Catalunya (FUOC). 1.2.3. Métodos de descomposición.
- [21] Chicco, D. & Jurman, G. (2020) *The advantages of the Matthews correlation coefficient (MCC) over F1 score and accuracy in binary classification evaluation*. BMC genomics. [Online] 21 (1), .
- [22] Borisov, V. et al. (2024) *Deep Neural Networks and Tabular Data: A Survey*. IEEE transaction on neural networks and learning systems. [Online] 35 (6), 7499–7519.
- [23] Barandas, M. et al. (2020) *TSFEL: Time Series Feature Extraction Library*. SoftwareX. [Online] 11.

- [24] Keany, E (2020) Boruta-Shap (Versión 1.1) [repositorio de código]. GitHub. Disponible en: <https://github.com/Ekeany/Boruta-Shap> (consultado el: 17 de marzo de 2026)
- [25] Kursa, M. B. & Rudnicki, W. R. (2010) *Feature Selection with the Boruta Package*. Journal of statistical software. [Online] 36 (11), .
- [26] Lundberg, S. & Lee, S.-I. (2017) *A Unified Approach to Interpreting Model Predictions*. Proceedings of the 31st International Conference on Neural Information Processing Systems. [Online] 4768–4777.
- [27] Barua, S., Islam, M.M., Yao, X. & Murase, K. (2014) ‘*MWMOTE – Majority Weighted Minority Oversampling Technique for Imbalanced Data Set Learning*’, IEEE Transactions on Knowledge and Data Engineering, 26(2), pp. 405–425. doi:10.1109/TKDE.2012.232.
- [28] Mahmoudi, S., Moradi, P., Akhlaghian, F. & Moradi, R. (2014) ‘*Diversity and separable metrics in over-sampling technique for imbalanced data classification*’, in 2014 4th International Conference on Computer and Knowledge Engineering (ICCKE), Mashhad, Iran, pp. 152–158. doi:10.1109/ICCKE.2014.6993409.
- [29] Bergstra, J., Yamins, D. y Cox, D. D. (2013) *Making a Science of Model Search: Hyperparameter Optimization in Hundreds of Dimensions for Vision Architectures*. Proceedings of the 30th International Conference on Machine Learning (JMLR: W&CP). [Online] vol. 28.
- [30] Subirats Maté, L. y Valiente Martos, M. (2026) *Modelos estadísticos y aprendizaje automático para el análisis de datos temporales II*. [Recurso de aprendizaje textual]. Primera edición. Barcelona: Fundació Universitat Oberta de Catalunya (FUOC). 1.5.5. Convolutional neural networks (CNN).
- [31] Subirats Maté, L. y Valiente Martos, M. (2026) *Modelos estadísticos y aprendizaje automático para el análisis de datos temporales II*. [Recurso de aprendizaje textual]. Primera edición. Barcelona: Fundació Universitat Oberta de Catalunya (FUOC). Tabla 3. Comparativa de modelos según complejidad y capacidad temporal.
- [32] TensorFlow (2024) *TensorFlow* v2.16.1: tf.config.experimental.enable_op_determinism. Disponible en: https://www.tensorflow.org/api_docs/python/tf/config/experimental/enable_op_determinism (Consultado: 10 de mayo de 2026).
- [33] Subirats Maté, L. y Valiente Martos, M. (2026) *Modelos estadísticos y aprendizaje automático para el análisis de datos temporales II*. [Recurso de aprendizaje textual]. Primera edición. Barcelona: Fundació Universitat Oberta de Catalunya (FUOC). 1.6.3. Arquitecturas modernas para la predicción de series temporales.

7. Anexos

1. Hiperparámetros para *BorutaSHAP*.

Algoritmo	Hiperparámetros
<i>LightGBM</i>	200 árboles, profundidad máxima 5 y hasta 20 hojas. Cada hoja final requiere al menos 30 observaciones. Se usa el 50% de variables por árbol, el 80% de variables por nodo y el 80% de observaciones por iteración. Además, <i>extra_trees=True</i> hace que <i>LightGBM</i> evalúe un único umbral aleatorio por variable en cada división. El desbalance se ajusta con el ratio por defecto: 10.5.
<i>XGBoost</i>	200 árboles y profundidad máxima 5. Cada hoja final requiere una suma mínima de pesos de instancia de 20. Se usa el 50% de variables por árbol, el 80% de variables por nodo y el 80% de observaciones por iteración. El entrenamiento se realiza con histogramas y el desbalance por defecto.
<i>CatBoost</i>	200 iteraciones y profundidad máxima 5. Cada hoja final requiere al menos 30 observaciones. Se usa el 50% de variables en cada selección de partición y el 80% de observaciones por árbol mediante muestreo Bernoulli. Desbalanceo por defecto.

Tabla Anexo 1. Configuración para *BorutaSHAP*.

2. Hiperparámetros para Optuna: *LightGBM*, *XGBoost* y *CatBoost*.

a) *LightGBM*

Tipo	Hiperparámetro	Rango evaluado	Función principal
Configuración fija	objective	binary	Clasificación binaria.
Configuración fija	metric	average_precision	Optimización orientada a <i>PR-AUC</i> .
Configuración fija	boosting_type	gbdt	Boosting basado en árboles de decisión.
Configuración fija	n_estimators	3500	Número máximo de árboles, limitado mediante <i>early stopping</i> .
Aprendizaje	learning_rate	0.005 - 0.1	Controla el peso de cada árbol añadido.
Estructura	max_depth	3 - 10	Profundidad máxima de los árboles.
Estructura	num_leaves	15 - 256	Número máximo de hojas; limitado por max_depth.

Estructura	min_child_samples	10 - 150	Número mínimo de muestras por hoja.
Aleatoriedad	extra_trees	True / False	Evalúa umbrales aleatorios en las particiones.
Regularización	path_smooth	0.0 - 10	Acerca la predicción de cada nodo a la de su nodo padre, reduciendo el sobreajuste en hojas con pocas muestras.
Regularización	min_split_gain	0.0 – 5.0	Ganancia mínima necesaria para dividir un nodo.
Discretización	max_bin	255 / 512	Número máximo de bins para variables continuas.
Muestreo	subsample	0.5 - 0.9	Proporción de filas usadas por iteración.
Muestreo	subsample_freq	1 - 5	Frecuencia de aplicación del submuestreo.
Muestreo	colsample_bytree	0.4 - 0.9	Proporción de variables usadas por árbol.
Regularización	reg_alpha	1e-4 - 20	Regularización L1.
Regularización	reg_lambda	1e-4 - 20	Regularización L2.
Desbalance	scale_pos_weight	1.0 - 10	Peso asignado a la clase fraudulenta.

Tabla Anexo 2. Rango de valores para *LightGBM*.

b) XGBoost

Tipo	Hiperparámetro	Rango evaluado	Función principal
Configuración fija	objective	binary:logistic	Clasificación binaria probabilística.
Configuración fija	eval_metric	aucpr	Evaluación mediante <i>PR-AUC</i> .
Configuración fija	tree_method	hist	Entrenamiento eficiente mediante histogramas.
Configuración fija	n_estimators	3500	Número máximo de árboles, limitado mediante <i>early stopping</i> .
Aprendizaje	learning_rate	0.005 - 0.1	Controla el peso de cada árbol añadido.
Estructura	max_depth	3 - 10	Profundidad máxima de los árboles.

Estructura	min_child_weight	1 - 50	Suma mínima de pesos necesaria en una hoja.
Discretización	max_bin	256 / 512	Número máximo de bins para variables continuas.
Muestreo	subsample	0.5 - 0.9	Proporción de filas usadas por árbol.
Muestreo	colsample_bytree	0.4 - 0.9	Proporción de variables usadas por árbol.
Muestreo	colsample_bylevel	0.5 - 1	Proporción de variables usadas por nivel.
Muestreo	colsample_bynode	0.5 - 1	Proporción de variables usadas por nodo.
Regularización	gamma	0.0 - 10	Ganancia mínima necesaria para dividir un nodo.
Regularización	reg_alpha	1e-4 - 20	Regularización L1.
Regularización	reg_lambda	1e-4 - 20	Regularización L2.
Desbalance	scale_pos_weight	1.0 - 10	Peso asignado a la clase fraudulenta.

Tabla Anexo 3. Rango de valores para *XGBoost*.

c) *CatBoost*

Tipo	Hiperparámetro	Rango evaluado	Función principal
Configuración fija	loss_function	Logloss	Función de pérdida para clasificación binaria.
Configuración fija	eval_metric	PRAUC	Evaluación mediante <i>PR-AUC</i> .
Configuración fija	iterations	3000	Número máximo de iteraciones, limitado mediante <i>early stopping</i> .
Aprendizaje	learning_rate	0.005 - 0.1	Controla el peso de cada árbol añadido.
Estructura	depth	4 - 7	Profundidad de los árboles simétricos.
Regularización	l2_leaf_reg	1.0 - 30	Regularización L2 en las hojas.
Aleatoriedad	random_strength	0.1 - 20	Ruido añadido al proceso de selección de particiones.

Muestreo	rsm	0.4 - 1.0	Proporción de variables consideradas en cada partición.
Muestreo	bootstrap_type	Bayesian / Bernoulli	Tipo de muestreo usado durante el entrenamiento.
Muestreo condicional	bagging_temperature	0.0 - 1.0	Intensidad del muestreo si bootstrap_type=Bayesian.
Muestreo condicional	subsample	0.5 - 0.9	Proporción de filas si bootstrap_type=Bernoulli.
Estructura	leaf_estimation_iterations	1 - 5	Iteraciones para estimar los valores de las hojas.
Discretización	border_count	128 / 200 / 254	Número de particiones para variables continuas.
Desbalance	scale_pos_weight	1.0 - 10.0	Peso asignado a la clase fraudulenta.

Tabla Anexo 4. Rango de valores para *CatBoost*.

3. Hiperparámetros optimizados de *XGBoost* en semilla única.

Hiperparámetro	Valor
objective	binary:logistic
eval_metric	aucpr
tree_method	hist
n_estimators	1275
learning_rate	0.03
max_depth	8
min_child_weight	1
max_bin	512
subsample	0.80
colsample_bytree	0.43
colsample_bylevel	0.76
colsample_bynode	0.8
gamma	0.15
reg_alpha	0.02
reg_lambda	0.03

scale_pos_weight	3.01
------------------	------

Tabla Anexo 5. Hiperparámetros finales de *XGBoost*.